Wk13-3 : 군집분석
- 비계층적 군집분석 -

1. 비계층적 군집분석

- 사전에 군집 수 k를 정한 후 각 객체를 k개 중 하나의 군집에 배정

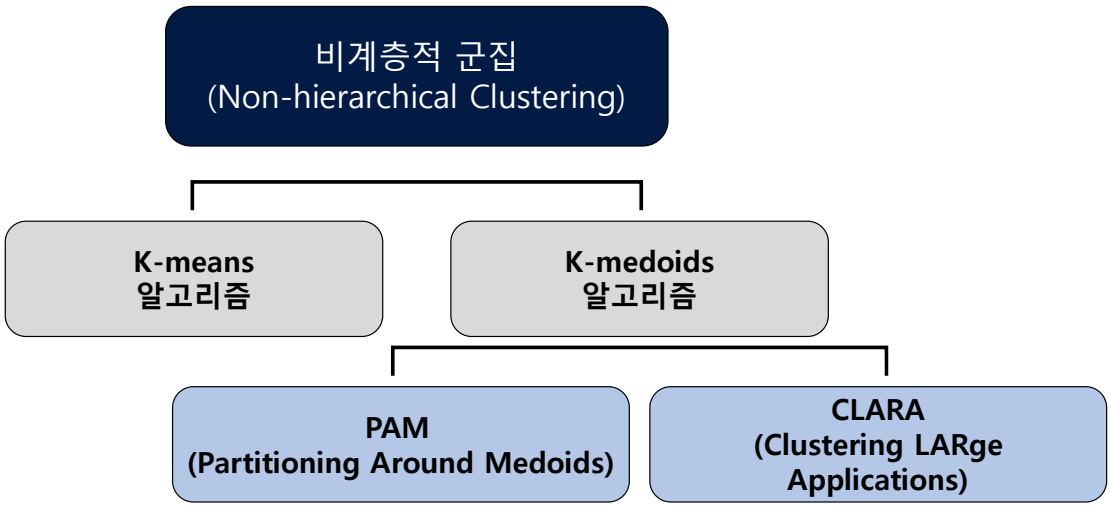

2. k-means 군집분석

• k-means 군집분석은 비계층적 군집분석 중 가장 널리 사용

- k개 군집의 중심좌표를 고려하여 각 객체를 가장 가까운 군집에 배정하는 것을 반복

[단계 0] (초기 객체 선정)
k개 객체 좌표를 초기 군집 중심좌표로 선정.

[단계 1] (객체 군집 배정)
각 객체와 k개 중심좌표와의 거리 산출 후, 가장 가까운 군집에 객체 배정.

[단계 2] (군집 중심좌표 산출)
새로운 군집의 중심좌표 산출.

[단계 3] (수렴 조건 점검)
새로 산출된 중심 좌표값과 이전 좌표값을 비교.
수렴 조건 내에 들면 종료, 그렇지 않으면 단계 1 반복.

3. k-means 군집분석 예제

• k-means 알고리즘을 적용 (군집 수 k=2라 가정)

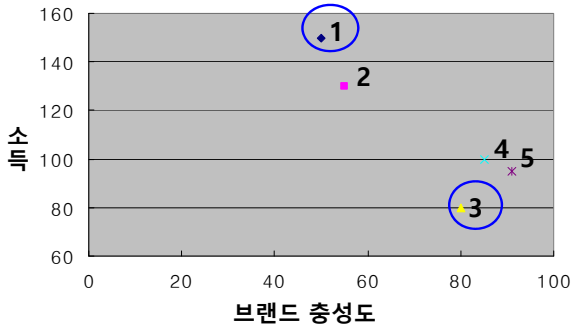

Step 0. 초기 객체 선정

- 임의의 두 객체 Obs1, Obs3 선정

Step 1. 객체 군집 배정

ID	1	3
1	**0.0**	76.2
2	**20.6** <	55.9
3	76.2	**0.0**
4	61.0 >	**20.6**
5	68.6 >	**18.6**

C1
Obs1, Obs2

C2
Obs3, Obs4, Obs5

3. k-means 군집분석 예제

• k-means 알고리즘을 적용 (군집 수 k=2라 가정)

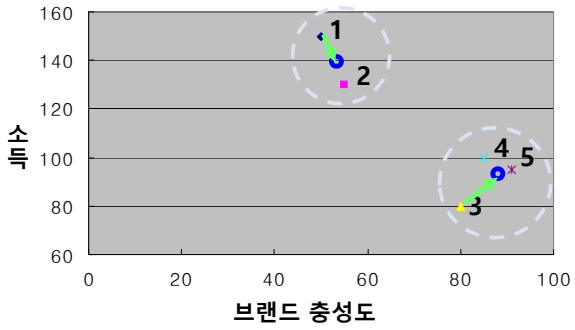

Step 2. 군집 중심좌표 산출

	C1	C2
객체	Obs1, Obs2	Obs3, Obs4, Obs5
중심좌표	$(\frac{50+55}{2}, \frac{150+130}{2})$ = (52.5, 140)	$(\frac{80+85+91}{3}, \frac{80+100+95}{3})$ = (85.33, 91.67)

Step 3. 수렴 조건 점검

ID	C1	C2
1	10.3 <	68.2
2	15.2	48.9
3	66.0	12.8
4	51.5 >	8.3
5	59.2	6.6

C1
Obs1, Obs2

C2
Obs3, Obs4, Obs5

이전 군집결과와 변화 없으므로, 본 해가 최종 군집해!

4. k-means 군집분석

• 데이터 불러오기 및 군집수 k 결정

```
#lec13_3_clus.R
# Clustering
# Non-hierarchical Clustering

# wage1833.csv : the wages of Lancashire co

# set working directory
setwd("D:/tempstore/moocr/wk13")

# read csv file
wages1833<-read.csv(file="wages1833.csv")
head(wages1833)

# preprocessing
dat1<-wages1833
dat1<-na.omit(dat1)
head(dat1, n=5)

# to choose the optimal k
install.packages("factoextra")
library(factoextra)
fviz_nbclust(dat1, kmeans, method = "wss")
```

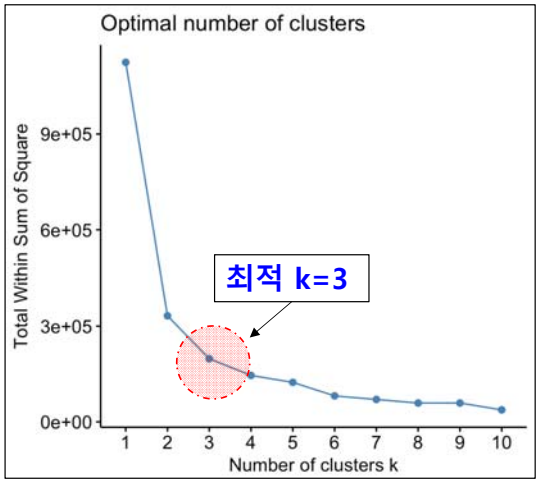

- 최적 군집수에 대한 시각화
- 최적값은 "silhouette", "gap_stat", "wss(그룹내합계제곱)" 으로 산출
- 그래프가 완만해지는 지점을 k의 값으로 추정

4. k-means 군집분석

• k-means (k=3)

k random set의 수 (nstart)

```
# compute kmeans
set.seed(123)
km <- kmeans(dat1, 3, nstart = 25)

# visualize
fviz_cluster(km, data = dat1,
             ellipse.type="convex",
             repel = TRUE)
```

- Kmeans 결과 시각화
- Convex 모양으로 구역 표시
- Repel을 통해 관측치 표기

```
> km
K-means clustering with 3 clusters of sizes 13, 10, 28

Cluster means:
   age      mnum      mwage      fnum     fwage
1 16.0 187.2308  96.36154 225.23077  71.0000
2 55.5   6.9000 178.99000   0.00000   0.0000
3 36.5  43.2500 241.73214  31.21429 107.9643
```

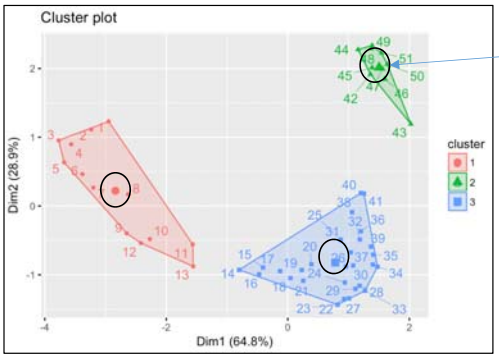

중심좌표

5. K-medoids 군집분석

• K-medoids 군집분석은 각 군집의 대표 객체(medoid)를 고려

- 군집의 대표 객체란, 군집 내 다른 객체들과의 거리가 최소가 되는 객체
- 즉, K-medoids 군집분석은 객체들을 K개의 군집으로 구분하는데,
- 객체와 속하는 군집의 대표 객체와의 거리 총합을 최소로 하는 방법
  - PAM 알고리즘: 모든 객체에 대하여 대표 객체가 변했을 때 발생하는 거리 총합의 변화를 계산.
    데이터 수가 많아질수록 연산량이 크게 증가함.
  - CLARA 알고리즘: 적절한 수의 객체를 샘플링 한 후, PAM 알고리즘을 적용하여 대표 객체 선정.
    샘플링을 여러 번 한 후 가장 좋은 결과를 택함.
    편향된 샘플링은 잘못된 결과값을 도출할 수 있음.

참고문헌: 전치혁, 데이터마이닝 기법과 응용, 2012, 한나래출판사

6. PAM (Partitioning Around Medoids) 알고리즘

• **PAM (k=3)**

```
# compute PAM
library("cluster")
pam_out <- pam(dat1, 3)
pam_out

# freq of each cluster
table(pam_out$clustering)

# visualize
fviz_cluster(pam_out, data = dat1,
             ellipse.type="convex",
             repel = TRUE)
```

```
> table(pam_out$clustering)

 1  2  3
13 28 10
```

```
> pam_out <- pam(dat1, 3)
> pam_out
Medoids:
    ID age mnum mwage fnum fwage
7    7  16  204  83.5  256    72
31 31  40   38 243.5   15   104
45 45  54   12 174.0    0     0
```

대표 객체