	단위별 학습내용 (Week5)
wk5-1	데이터시각화 : R그래픽
wk5-2	R 그래픽 : ggplot2의 활용
wk5-3	R 그래픽 : 3D와 히트맵
wk5-4	R 그래픽 : 공간지도분석

이혜선

POSTECH 산업경영공학과

email: hyelee@postech.ac.kr

web: http://www.postech.ac.kr/~hyelee/



5-1. 데이터시각화 : R그래픽


Wk5-1 : 데이터시각화

- R 그래픽 -

5-1. 데이터시각화 : R그래픽

R 그래픽 - 데이터시각화

•추가패키지 설치 (install.packages)



* 해당패키지를 사용할때 library(lattice)는 매번 필요함 !!!



3

R그래픽: 데이터시각화

5-1. 데이터시각화 : R그래픽

- 1. R 기본 그래픽스 (Base에 포함되어 있음)
- 2. Lattice 그래픽스: 직교형태의 멀티패널 툴
- 3. ggplot2 그래픽 시스템 : Hadley Wickham이 구현
- (1) Grammar of Graphic라는 개념은 그래픽을 생성할때 각 요소를 구분하여 취급한다는 의미
- (2) Incremental graphic : 기본 R그래픽스보다 인터액티브한 그래프를 그릴수 있음. 기초 그림을 생성한 후 그래픽스 요소를 필요에 따라 붙이거나 수정

5-1. 데이터시각화 : R그래픽

R그래픽: 데이터시각화

lattice: 직교형태의 그래픽툴

• lattice 함수 : xyplot, bwplot, contourplot, levelplot 등

(1)xyplot : 산점도

(2) bwplot: box whiskers plot, 상자그림

(3) dotplot

(4) level plot

(5) stripplot : 점을 함께 표시한 상자그림

(6) splom : 산점도 매트릭스

(7)contourplot: 등고선그림



5

lattice 설치와 사용

5-1. 데이터시각화 : R그래픽

·lattice : 직교형태의 그래픽툴

POSTECH

5-1. 데이터시각화 : R그래픽

lattice 설치와 활용

·lattice 패키지의 데이터 사용

프로그램 편집창

```
# lec5_2.r
# Grapic using lattice
install.packages('lattice')
library(lattice)
# ethanol data in lattice
help("ethanol")
```

데이터 ethanol (lattice패키지에 들어있는 실습데이터)

```
A data frame with 88 observations on the following 3 variables.

NOx

Concentration of nitrogen oxides (NO and NO2) in micrograms/J.

C

Compression ratio of the engine.

E

Equivalence ratio—a measure of the richness of the air and ethanol fuel mixture.
```



_

lattice 활용 그래픽

5-1. 데이터시각화 : R그래픽


·lattice 패키지의 데이터 ethanol

```
# ethanol data in lattice
                               > head(ethanol)
help("ethanol")
                                   NOx C
                               1 3.741 12 0.907
head(ethanol)
                               2 2.295 12 0.761
dim(ethanol)
                               3 1.498 12 1.108
str(ethanol)
                               4 2.881 12 1.016
                               5 0.760 12 1.189
                               6 3.120 9 1.001
                               > dim(ethanol)
                               [1] 88 3
                                > str(ethanol)
                                'data.frame':
                                               88 obs. of 3 variables:
                                $ Nox: num 3.74 2.29 1.5 2.88 0.76 ...
                                $ C : num 12 12 12 12 12 9 9 9 12 12 ...
                                $ E : num 0.907 0.761 1.108 1.016 1.189 ...
                               > table(ethanol$C)
 table(ethanol$C)
                               7.5
                                         12
                                             15
                                22
                                    17
                                         14
                                              19
                                                   16
```

POSTECH
POHANG UNIVERSITY OF SCIENCE AND TECHNOLOGY

lattice 활용 그래픽

lattice함수 xyplot을 이용한 그래프 (기본 산점도와 동일)




POSTELH OHANG UNIVERSITY OF SCIENCE AND TECHNOLOGY

5-1. 데이터시각화 : R그래픽

lattice 활용 그래픽


xyplot을 이용한 멀티패널 산점도 : xyplot(y변수~x변수 | 조건부변수, data=)



5-1. 데이터시각화: R그래픽

lattice 활용 그래픽

xyplot을 이용한 멀티패널 산점도 (subset 데이터)





R그래픽: 데이터시각화

5-1. 데이터시각화: R그래픽

- http://www.r-graph-gallery.com/portfolio/ggplot2-package/
- http://www.cookbook-r.com/Graphs/
- http://gglots.org : ggplot2공식 사이트
- http://docs.ggplot2.org : 하위 옵션 사용법 및 예제
- http://groups.google.com/group/ggplot2
- R을 활용한 데이터시각화, 유충현, 홍성학



Wk5-2 : R 그래픽

- ggplot2 활용-




ⓒ포항공대 산업경영공학과 이혜선

5-2. R그래픽 : ggplot2 활용

•추가패키지 설치 (install.packages)

lec5_2.r # Grapic using ggplot2 # set working directory setwd("D:/tempstore/moocr") # library install.packages('ggplot2') library(ggplot2) 2





Grammar of graphics

- (1) ggplot()이라는 기본 함수
- +
- (2-1) Layers : aes (Aesthetic) : 데이터를 어떻게 넣을건지
- (2-2) Layer : geom (Geometric objects) : point(점), line(선) 등
- (2-3) Layer: coor (coordinate system)
- 1. scale+coordinate system은 그림을 그릴때 캔버스로 생각하면 됨
- 2. 그 위에 data+mapping+geom을 추가
- 3. geom(기하학적 요소): geom_point, geom_smooth등을 이미 그려진 산점도에 추가하여(incremental) 그릴수 있음



3

R 그래픽: ggplot2 그래프


5-2. R그래픽 : ggplot2 활용

• ggplot(데이터이름, aes(x=x축변수, y=y축변수, color=factor변수, shape=factor변수))+geom_point(size=3)

```
# lec5 2.r
# Grapic using ggplot2
# set working directory
setwd("D:/tempstore/moocr")
                                               Step0 : 분석을 위한 설정(library, package, setwd)
# library
# install.packages('ggplot2')
library(ggplot2)
# Read in R : autompg data
car<-read.csv("autompg.csv")</pre>
head(car)
                                                            Step 1: 데이터핸들링
str(car)
                                                            (불러들이기, subset, 변수값정의)
# subset of car : cyl (4,6,8)
car1<-subset(car, cyl==4 | cyl==6 | cyl==8)
attach(car1)
# 5-1 ggplot2 for scatterplot
# Color and shape display by factor (categorical variable)
# check the variable type(integer, numeric, factor) and define
str(car1)
car1$cyl<-as.factor(car1$cyl)
# Now, you can draw one of plot using ggplot
                                                                            Step2: 데이터탐색
ggplot(car1, aes(x=wt, y=disp, color=cyl, shape=cyl)) +
 geom_point(size=3)
```

5-2. R그래픽 : ggplot2 활용

5-1. ggplot2: scatterplot by group (cyl) 변수 (lec5_2.R)





5

R 그래픽: ggplot2 그래프

5-2. R그래픽 : ggplot2 활용

5-1. ggplot2: ggplot객체들의 설명

```
# 5-1 ggplot2 for scatterplot
# Color and shape display by factor (categorical variable)
# check the variable type(integer, numeric, factor) and def
str(car1)
car1$cy1<-as.factor(car1$cy1)
# Now, you can draw one of plot using ggplot
ggplot(car1, aes(x=wt, y=disp, color=cy1, shape=cy1)) +
    geom_point(size=3)</pre>
```

ggplot(car1, aes(x=wt, y=disp, color=cyl, shape=cyl))

1. ggplot함수에 데이터는 car1을 이용하고, x축에는 wt(차의 무게)를, y축에는 disp(배기량)의 산점도를 그리고, 점의 색상은 cyl(실린더 수)로 표현한다


geom point(size=3, alpha=0.6)

2. geom_point는 size=3(숫자 클수록 점 크기가 커짐)

POSTECH

5-1. mpg의 크기를 표시한 그래프

mapping (continuous variable : mpg) on the scatterplot for wt and disp
ggplot(car1, aes(x=wt, y=disp, color=mpg, size=mpg)) +
 geom_point(alpha=0.6)



POSTECH

R 그래픽: ggplot2 구조

5-2. R그래픽 : ggplot2 활용

ggplot의 기본

ggplot : 새로운 ggplot을 생성 aes : aesthetic mapping을 구성 (데이 터, 그래프구조) qplot: 즉석 그림


geom 함수군

geom_abline, geom_hline, geom_vline
geom_bar
geom_point
geom_boxplot
geom_map
geom_smooth, stat_smooth

geom (geometric) 함수군

geom메뉴	help.search("geom")			
ggplot2::geom_abline	Reference lines: horizontal, vertical, and diagonal			
ggplot2::geom_bar	Bars charts			
ggplot2::geom_bin2d	Heatmap of 2d bin counts			
ggplot2::geom_blank	Draw nothing			
ggplot2::geom_boxplot	A box and whiskers plot (in the style of Tukey)			
ggplot2::geom_contour	2d contours of a 3d surface			
ggplot2::geom_count	Count overlapping points			
ggplot2::geom_density	Smoothed density estimates			
olot2::geom_density_2d	Contours of a 2d density estimate			
ggplot2::geom_dotplot	Dot plot			
gplot2::geom_errorbarh	Horizontal error bars			
ggplot2::geom_hex	Hexagonal heatmap of 2d bin counts			
ggplot2::geom_freqpoly	Histograms and frequency polygons			
ggplot2::geom_jitter	Jittered points			
gplot2::geom_crossbar	Vertical intervals: lines, crossbars & errorbars			
ggplot2::geom_map	Polygons from a reference map			
ggplot2::geom_path	Connect observations			
ggpl <mark>ot2::qeom_point</mark>	Points			
ggplot2::geom_polygon	Polygons			
ggplot2::geom_qq	A quantile-quantile plot			

5-1. geom_bar 을 이용한 단계별 그래프 설명




POSTELH POHANG UNIVERSITY OF SCIENCE AND TECHNOLOGY

9

R 그래픽: ggplot2 그래프

5-2. R그래픽 : ggplot2 활용

5-2. geom_bar 을 이용한 누적 막대그래프





5-2. geom_bar 을 이용한 누적 막대그래프- 한글제목 넣기



POSTECH

11

R 그래픽: ggplot2 활용

5-2. R그래픽 : ggplot2 활용

5-3. ggplot 산점도에 회귀선 넣기 : step1

autpmpg 데이터 사용: 차량무게에 따른 연비 예측


```
# 5-3 ggplots for scatterplot with regression line
# step1 : # Use hollow circles
ggplot(car1, aes(x=wt, y=mpg))+geom_point(shape=1)

ggplot(데이터이름, aes(x=x축변수, y=y축변수))
geom_point(shape=1, size=)
```

POSTECH

R 그래픽 : ggplot2 활용

5-3. ggplot 산점도에 회귀선 넣기 : step2



POSTECH

12

R 그래픽 : ggplot2 활용


5-2. R그래픽 : ggplot2 활용

5-3. ggplot 산점도에 회귀선 넣기 : step2

- 옵션 : 신뢰구간이 없는 회귀선 -

R 그래픽 : ggplot2 활용

5-3. ggplot 산점도에 비선형회귀식 적합 : step3





15

ggplot2 그래픽 사이트

5-2. R그래픽 : ggplot2 활용

• R-studio의 ggplot2활용 요약

https://www.rstudio.com/wp-content/uploads/2015/03/ggplot2-cheatsheet.pdf







Wk5-3: R 그래픽-3D, 히트맵




ⓒ포항공대 산업경영공학과 이혜선

R 추가패키지

5-3. R그래픽-3D, 히트맵


•추가패키지 설치 (install.packages)





3-D plot

• 3D scatterplot : scatterplot(데이터\$변수, pch= , ...)





3-D plot

5-3. R그래픽-3D, 히트맵

• 데이터 trees에 관하여 : help(trees), head(tress), write.csv(....)

```
# to know about data "trees"
help(trees)
head(trees)


# export to csv file
write.csv(trees,file="trees.csv", row.names = FALSE)
```

도움말

trees 데이터
Girth : 체리나무의 지름 (inch)
Height : 체리나무의 키 (feet)
Volume : 나무의 부피(ft^3)

⇒ 나무의 둘레(x1)와 키(x2)로 목재
의 부피(y)를 예측

⇒ y=f(x1, x2)





3-D plot

•데이터 내보내기 (실습)

프로그램 편집창


```
# to know about data "trees"
help(trees)
head(trees)

# export to csv file
write.csv(trees,file="trees.csv", row.names = FALSE)
```

컨솔창

```
> head(trees)
 Girth Height Volume
  8.3
          70
               10.3
   8.6
           65
                10.3
   8.8
           63
                10.2
4 10.5
               16.4
           72
 10.7
           81
                18.8
6 10.8
           83
                19.7
> write.csv(trees,file="trees.csv", row.names = FALSE)
```

현재 작업창 : working directory



□ ⊕ 5 * ≥ * =

파일	별	산입 폐	이지 레이아운	4
	3 × .	맑은 고딕		11 -
분여	#21 3	7 7 <u>7</u> .	H - 2	· <u>Zt</u> ·
90	ger c		글끝	
Н9	*	: 🔀	√ fx	
	A	В	С	
1	Girth	Height	Volume	
2	8.3	70	10.3	
3	8.6	65	10.3	
4	8.8	63	10.2	
5	10.5	72	16.4	
6	10.7	81	18.8	
7	10.8	83	19.7	
8	11	66	15.6	
9	11	75	18.2	
10	11.1	80	22.6	
11	11.2	75	19.9	
12	11.3	79	24.2	
13	11.4	76	21	
14	11.4	76	21.4	

POSTELH POHANG UNIVERSITY OF SCIENCE AND TECHNOLOGY

3-D plot

5-3. R그래픽-3D, 히트맵


• 3D 산점도에 선형식 추가

5-3 3D scatterplot with data trees

lm(linear <mark>m</mark>odel) lm(y변수~x변수+x변수+..) 여기서는 y변수(나무의 부피), x변수(나

여기서는 y변수(나무의 부피), x변수(나무의 지름, 키) => 나무의 부피는 나무의 지름이 클수록, 나무의 키가 클수록 크다

- 1. 산점도를 s3d(이름은 자유로 지정)로 저장하고,
- 2. s3d의 요소중 planed3d에 lm(Volume~Girth+Hieght) 의 선형식을 추가





POSTECH
POHANG UNIVERSITY OF SCIENCE AND TECHNOLOGY

히트맵 (heatmap)

• 히트맵 : 통계치를 구한후 크기에 비례하여 그라데이션 색상으로 표현한 시각화기법. 색상을 열의온도를 연상하게 해서 열(heatmap)이라고 함

Autompg 데이터의 상관계수를 이용한 히트맵





POSTECH

히트맵 (heatmap)

5-3. R그래픽-3D, 히트맵

•데이터 : USArrest (미국범죄율 데이터, 1973년)

```
# Crime rate by US State (1973)
# Arrests per 100,000 residents for assault, murder, and rape
# in each of the 50 US states in 1973
help(USArrests)
head(USArrests)
```

상관계수(변수간 상관관계)

cor(USArrests)
round(cor(USArrests), 2)

> head(USArrests)						
	Murder	Assault	UrbanPop	Rape		
Alabama	13.2	236	58	21.2		
Alaska	10.0	263	48	44.5		
Arizona	8.1	294	80	31.0		
Arkansas	8.8	190	50	19.5		
California	9.0	276	91	40.6		
Colorado	7.9	204	78	38.7		

> round(cor(USArrests), 2)							
	Murder	Assault	UrbanPop	Rape			
Murder	1.00	0.80	0.07	0.56			
Assault	0.80	1.00	0.26	0.67			
UrbanPop	0.07	0.26	1.00	0.41			
Rape	0.56	0.67	0.41	1.00			




히트맵 (heatmap)

• 미국 (1973년, State별 범죄) 4개변수들중 UrbanPop(도심인구비율) 변수는 제외한 행렬

```
# subset excluding 3th variable UrbanPop
x <- as.matrix(USArrests[, -3]
result <- heatmap(x, scale="column", Colv=NA, cexCol=1,
                 main="Violent Crime Rates by US State (1973)")
```

인구 십만명당 폭행, 살인, 성범죄 비율에 따른 히트맵 : 범죄비율이 높은 주부터 낮 은 주를 표시 (빨강색이 범죄율 낮은 주)



POSTECH

5-3. R그래픽-3D, 히트맵

히트맵 (heatmap)

• 데이터 (미국 주별 범죄발생, 1973년)

```
# subset excluding 3th variable UrbanPop
x <- as.matrix(USArrests[, -3])</pre>
result <- heatmap(x, scale="column", Colv=NA, cexCol=1,
                  main="Violent Crime Rates by US State (1973)"
row.names(USArrests)[result$rowInd[1:10]]
row.names(USArrests)[result$rowInd[35:50]]
```

범죄발생 낮은주(10개주 1:10)

```
> row.names(USArrests)[result$rowInd[1:10]]
[1] "Minnesota"
                     "South Dakota" "Maine"
                                                      "West Virginia'
 [5] "Hawaii"
                     "North Dakota" "Vermont"
                                                      "Wisconsin"
[9] "New Hampshire" "Iowa"
```

범죄발생 높은주 (16개주 35:50)

```
> row.names(USArrests)[result$rowInd[35:50]]
[1] "North Carolina" "Florida"
                                        "Arizona"
                                                          "Marvland"
                      "South Carolina" "New Mexico"
[5] "California"
                                                          "Alaska"
[9] "Michigan"
                      "Nevada"
                                        "Delaware"
                                                          "Alabama"
[13] "Mississippi"
                       "New York"
                                                          "Louisiana"
                                        "Illinois"
```





Wk5-4: R 그래픽-공간지도분석



ⓒ포항공대 산업경영공학과 이혜선

R 추가패키지 설치

5-4. R그래픽-공간지도분석

•추가패키지 설치 (install.packages)

```
# lec5_4.R

#install.packages("ggplot2")
library(ggplot2)

# maps : world map
install.packages("maps")
library(maps)

# mapdata : more world map
install.packages("mapdata")
library(mapdata)

# mapdata : latitude and longitude
install.packages("mapproj")
library(mapproj)
```

- 1. maps 세계의 지도 데이터베이스
- 2. mapdata maps보다 정교한 지도
- 3. mapproj 위도와 경도
- 4. ggplot2 R 그래픽 패키지

POSTELH
POHANG UNIVERSITY OF SCIENCE AND TECHNOLOGY

5-4. R그래픽-공간지도분석

R그래픽: 공간지도

• 한국지도 : maps와 mapdata를 이용한 지도

```
# using map package
| bar(mfrow = c(1, 2),mar=c(2,2,2,2))
| map(database = 'world', region = c('South Korea', 'North Korea'), col='green', fill = TRUE)
| title("Korea")
| # using mapdata package
| map(database = 'worldHires'), region = c('South Korea', 'North Korea'), col='green', fill = TRUE)
| title("Korea")

| Korea | Kor
```

R그래픽: 공간지도

5-4. R그래픽-공간지도분석

•지도:이탈리아

```
# 2.Italy
par(mfrow = c(1, 1),mar=c(2,2,2,2))
map(database = 'world', region = c('Italy'), col='coral', fill = TRUE)
title("Italy")
```




POSTREH

R그래픽: 공간지도

• mapproj 패키지 - 위도, 경도 활용 (독도를 표시)

```
# Dokdo map using mapproj package
library(mapproj)
map('world', proj = 'azequalarea', orient = c(37.24223, 131.8643, 0))
map.grid(col = 2)
points(mapproject(list(y = 37.24223, x = 131.8643)), col = "blue", pch = "x", cex = 2)
title("Dokdo")
# for reading Korean : encoding to UTF-8
                                                                           Dokdo
# file menu: Tools_global options_code_saving
```





공간지도분석 예제 1: 국내공항 및 항공노선

5-4. R그래픽-공간지도분석

•국내 공항 및 노선 현황

```
# 4. Airport & route data (source : https://www.data.go.kr/)
airport<-read.csv("airport.csv")
route = read.csv("route.csv")
head(airport)
head(route)
head(route[order(route$id),])
```

air	port.csv	: 국	내 공항	위치 7	정보	
he	ead(airpo	ort)				
	airport	iata	a lo	n i	lat	
1	강릉	KAG	128.944	37.75	36	
2	광주	KWJ	126.809	35.12	54	
3	군산	KUV	126.616	35.903	38	
4	김포	GMP	126.791	37.55	83	
5	대구	TAE	128.659	35.89	41	
6	목포	MPK	126.380	34.75	89	

route.csv : 국내선 노선 정보

	id	airport	lon	lat		id	airport		
1	1	CJJ	127.499	36.7166	1	1	CJJ	127.499	36.7166
2	7	CJJ	127.499	36.7166	83	1	CJU	126.493	33.5113
3	45	CJJ	127.499	36.7166	2	2	CJU	126.493	33.5113
4	77	CJJ	127.499	36.7166	84	2	CJJ	127.499	36.7166
5	2	CJJ	127.499	36.7166	3	3	CJU	126.493	33.5113
6	8	CJJ	127.499	36.7166	85	3	GMP	126.791	37.5583
							항공	노선	


id기준 정렬

head(route[order(route\$id),])

공간지도분석 예제 : 국내공항 및 항공노선

•국내 공항위치

south korea airports





7

공간지도분석과 ggplot


5-4. R그래픽-공간지도분석


• ggplot 은 레이어를 추가하는 방식으로 그래픽을 구현


ggplot(data=kr.map, aes(x=long, y=lat, group=group)) +
geom_polygon(fill="white", colour="black")

ggplot(data=kr.map, aes(x=long, y=lat, group=group))

ggplot() +
geom_polygon(data=kr.map, aes(x=long, y=lat, group=group)) +
geom_label(data=airport, aes(x = lon, y = lat, label=iata))
labs(title = "south korea airports")










공간지도분석 예제 : 미국 행정데이터

•지도 데이터베이스와 행정자료 결합 : 미국 (1973) 범죄수 지도




POSTECH POHANG UNIVERSITY OF SCIENCE AND TECHNOLOGY

공간지도분석 예제 : 미국 행정데이터

5-4. R그래픽-공간지도분석

• 행정자료 (USArrests 는 기본프로그램에 포함된 데이터)



> head(USArrests)						
	Murder	Assault	UrbanPop	Rape		
Alabama	13.2	236	58	21.2		
Alaska	10.0	263	48	44.5		
Arizona	8.1	294	80	31.0		
Arkansas	8.8	190	50	19.5		
California	9.0	276	91	40.6		
Colorado	7.9	204	78	38.7		





	데이터탐색 (Week6)
wk6-1	데이터 다루기
wk6-2	데이터의 기술통계치요약
wk6-3	그래프를 이용한 데이터탐색
wk6-4	데이터의 정규성검정과 신뢰구간



6-1. 데이터 다루기 (데이터결합, 분할, 정렬)

Wk6-1 : 데이터 다루기

- 데이터결합, 분할, 정렬 -

•데이터 결합: merge(data1, data2, by="ID")

data1과 data2는 아래와 같이 식별변수 ID를 기준으로 결합

data1: 게임장르, 나이, 성별 data2: 주당게임시간, 음주경험, 흡연경험

data2.csv

data1.c	sv		
Α	В	С	D
ID	age	gender	game
111	16	F	RTS
112	17	F	FPS
113	15	М	Sport
114	18	М	MMORPG
115	14	F	MMORPG
116	15	F	FPS
117	13	М	Sport
118	19	F	FPS
119	17	М	Sport
120	18	F	RTS

В	С	D
hourwk	alcohol	smoke
10	yes	yes
8	no	no
4	no	no
10	no	no
2	no	yes
10	yes	yes
12	yes	yes
8	no	no
6	no	no
4	no	no
	hourwk 10 8 4 10 2 10 12 8 6	hourwk alcohol 10 yes 8 no 4 no 10 no 2 no 10 yes 12 yes 8 no 6 no

	ID age gender game hourwk alcohol smoke							
	ID ÷	age ÷	gender	game ÷	hourwk	alcohol	smoke	
1	111	16	F	RTS	10	yes	yes	
2	112	17	F	FPS	8	no	no	
3	113	15	М	Sport	4	no	no	
4	114	18	м	MMORPG	10	no	no	
5	115	14	F	MMORPG	2	no	yes	
6	116	15	F	FPS	10	yes	yes	
7	117	13	М	Sport	12	yes	yes	
8	118	19	F	FPS	8	no	no	
9	119	17	М	Sport	6	no	no	
10	120	18	F	RTS	4	no	no	




2

데이터 다루기

6-1. 데이터 다루기 (데이터결합, 분할, 정렬)

•데이터 결합: merge(data1, data2, by="ID")

dat1과 dat2를 ID를 기준으로 결합 (관측치수는 동일함, 변수들의 정보가 추가됨)





	ID ÷	age ÷	gender	game +	hourwk	alcohol	smoke
- 1	111	16	Е	RTS	10	yes	yes
2	112	17	F	FPS	8	no	no
3	113	15	М	Sport	4	no	no
4	114	18	М	MMORPG	10	no	no
5	115	14	F	MMORPG	2	no	yes
6	116	15	F	FPS	10	yes	yes
7	117	13	М	Sport	12	yes	yes
8	118	19	F	FPS	8	no	no
9	119	17	М	Sport	6	no	no
10	120	18	F	RTS	4	no	no




•데이터 결합: rbind(data3, data4)

data3과 data4가 동일한 변수들을 갖고 있을때 두개 데이터를 행(row)으로 결합



data3	-	-	-	-		-
ID	age	gender	game	hourwk	alcohol	smoke
121	20	F	RTS	10	yes	yes
122	21	F	FPS	8	no	no
123	20	M	Sport	12	no	no



POSTECH

5

데이터 다루기

6-1. 데이터 다루기 (데이터결합, 분할, 정렬)

•데이터 정렬: 데이터이름[order(변수1, 변수2),]

변수1로 먼저 정렬을 하고 그다음 변수2로 정렬


```
# data sorting
dats1<-dat12[order(dat12$age),]
dats1
dats2<-dat12[order(dat12$gender, dat12$age), ]
dats2</pre>
```

연령별(age)로 정렬

```
> dats1<-dat12[order(dat12$age),]</pre>
  dats1
                      game hourwk alcohol smoke
    ID age gender
   117
                     Sport
                                 12
         13
                                        yes
                                               yes
5
   115
                  F MMORPG
         14
                                  2
                                          no
                                               yes
3
   113
         15
                     Sport
                                         no
                                                no
6
   116
         15
                       FPS
                                 10
                                        yes
                                               yes
1
   111
         16
                  F
                       RTS
                                 10
                                        yes
                                               yes
2
   112
         17
                       FPS
                                  8
                                          no
                                                no
   119
         17
                  M Sport
                                  6
                                          no
                                                no
   114
                  M MMORPG
                                 10
                                          no
                                                no
         18
10 120
                       RTS
                                  4
                  F
                                          no
                                                no
                                  8
   118
                       FPS
                                                no
```



•데이터 정렬: 데이터이름[order(변수1, 변수2),]





7

데이터 다루기

6-1. 데이터 다루기 (데이터결합, 분할, 정렬)

• 데이터 추출 - subset(데이터이름, 조건1 & 조건2)


dat12에서 gender=F이고 age>15이상인 데이터를 newdat라는 이름의 데이터로 저장

```
# data subset (selecting data)
#newdat<-dat12[which(dat12$gender=="F" & dat12$age>15),]
newdat<-subset(dat12, dat12$gender=="F" & dat12$age>15)
newdat
                                          > newdat<-subset(dat12, dat12$gender=="F" & dat12$age>15)
                                           newdat
                                              ID age gender game hourwk alcohol smoke
                                          1
                                             111
                                                          F
                                                             RTS
                                                                      10
                                                 16
                                                                             yes
                                                                                    yes
                                             112
                                                  17
                                                              FPS
                                                                       8
                                             118
                                                  19
                                                                       8
                                                          F
                                                             FPS
                                                                              no
                                                                                     no
                                          10 120
                                                  18
                                                              RTS
                                                                              no
                                                                                     no
```



• 데이터에서 일부변수 제거하기 - 데이터이름[!names(데이터) %in% c("변수1","변수2")]

dat12에서 age와 gender를 제외하고 exdat라는 이름의 데이터로 저장 (!는 not을 의미)






(

데이터분석:데이터 사이언티스트

6-1. 데이터 다루기 (데이터결합, 분할, 정렬)

•데이터 핸들링 -> 데이터 탐색 -> 통계적 모델링 (통계모형, 기계학습, 인공지능)

탐색적 데이터분석



통계적 분석기법

상관분석 (X,Y 모두 continuous variable) 일반적으로 0.7이상이면 높다고 보지만 절대적 기준은 없다.

Tukey multiple comparisons of means 95% family-wise confidence level

post-noc analysis Tukey il <- acv(value - drug + age) posthoc <- TukeyHSD(x=al, 'drug', conf.level=0.95)

카이제곱분석 -범주형 변수간 상관관계 (X,Y 모두 범주형 변수) 유의수준 0.1, 0.05에서 판단

분산분석(ANOVA) 매장평수별 판매금액, 횟수의 차이 그룹간 유의한 차이는 0.05, 0.1에서 결정

> 구매 중요 요인 도출 (마케팅) 불량 요인 도출 (제조업) 위험요인 도출 (금융업)





Wk6-2: 데이터의 기술통계치요약



ⓒ포항공대 산업경영공학과 이혜선

6-2. 데이터의 기술통계치요약

데이터 기술통계치요약

- •데이터: 학생들의 학업성취도* (포루투칼의 고등학생 수학점수)
- http://archive.ics.uci.edu/ml/datasets/Student+Performance

st	tud_n	nath.c	SV										
	Α	В	С	D	E	F	G	Н	I	J	K	L	
1	school	sex	age	address	famsize	Pstatus	Medu	Fedu	Mjob	Fjob	reason	guardian	trav
2	GP	F	18	U	GT3	Α	4	1 4	at_home	teacher	course	mother	
3	GP	F	17	U	GT3	T	1	L	L at_home	other	course	father	
4	GP	F	15	U	LE3	T	1	L :	L at_home	other	other	mother	
5	GP	F	15	U	GT3	T	4	1	health	services	home	mother	
6	GP	F	16	U	GT3	T	3	3	other other	other	home	father	
7	GP	M	16	U	LE3	T	4	1	services	other	reputation	mother	
8	GP	М	16	U	LE3	T	2	2	other	other	home	mother	
9	GP	F	17	U	GT3	Α	4	1 4	1 other	teacher	home	mother	
10	GP	M	15	U	LE3	Α	3	3	services	other	home	mother	
11	GP	M	15	U	GT3	T	3	3	1 other	other	home	mother	
12	GP	F	15	U	GT3	T	4	1 .	1 teacher	health	reputation	mother	
13	GP	F	15	U	GT3	T	2	2	L services	other	reputation	father	
14	GP	M	15	U	LE3	T	4	1 4	l health	services	course	father	
15	GP	M	15	U	GT3	Т	4	1	teacher 1	other	course	mother	

^{*} P. Cortez and A. Silva. Using Data Mining to Predict Secondary School Student Performance. In A. Brito and J. Teixeira Eds., Proceedings of 5th FUture BUsiness TEChnology Conference (FUBUTEC 2008) pp. 5-12, Porto, Portugal, April, 2008, EUROSIS, ISBN 978-9077381-39-7.



•데이터설명 (stud math desc.doc참고)

school: 학교이름 (GP, MS)

sex : 성별 (F, M) age : 나이 (15-22)

address: 주소 (Urban:도심, Rural:외곽) famsize : 가족수 (LE3 :≤3, GT3: >3)

Medu: 엄마교육수준 Fedu: 아빠교육수준

traveltime: 통학시간: 1(15분이하),2,3,4(1시간이상)

studytime: 주중공부시간: 1(<2시간), 2(2-5시간), 3(5-10시간),

4(>10시간)

activties : 방과후활동(yes, no) nursery:유치원다녔는지여부(yes,no) internet: 집에서 인터넷사용(yes,no) romantic: 이성교제여부(yes, no) soout : 친구들과 외출 (1-5)

Dalc: 음주(1-5)

health: 건강상태 (1(매우나쁨)-5(매우좋음))

absences : 학교결석 (0-93)

타겟변수: G3(최종성적, 0-20), G2(2학년), G1(1학년)

POSTPCH

Attribute Information:

- # Attributes for both student-mat.csv (Math course) and student-por.csv (Portuguese language course) datasets:
 1 school student's school (binary: 'GP' Gabriel Pereira or 'MS' Mousinho da Silveira)
 2 sex student's save (binary: 'F' Female or 'M' male)
 3 age student's age (numeric: from 15 to 22)
 4 address student's home address type (binary: 'U' urban or 'R' rural)
 5 famsize family size (binary: 'LE3' less or equal to 3 or 'GT3' greater than 3)
 6 Pstatus parent's corhabitation status (binary: 'T' living logether or 'A' apart)
 7 Medu mother's education (numeric: 0 none, 1 primary education (4th grade), 2 â€⁻ 5th to 9th grade, 3 â€⁻ secondary educ 8 Fedu father's education (numeric: 0 none, 1 primary education (4th grade), 2 â€⁻ 5th to 9th grade, 3 â€⁻ secondary educ 8 Fedu father's education (numeric: 0 none, 1 primary education (4th grade), 2 â€⁻ 5th to 9th grade, 3 â€⁻ secondary educ 9 Mjob mother's job (nominal: 'teacher', health' care related, civil 'services' (e.g. administrative or police), 'at home' or 'other')
 10 Fjob father's job (nominal: 'teacher', 'health' care related, civil 'services' (e.g. administrative or police), 'at home' or 'other')
 11 reason reason to choose this school (nominal: close to 'home', school 'reputation', 'course' preference or 'other')
 12 guardian student's guardian (nominal: 'mother', 'father' or 'other')
 13 traveltime home to school travel time (numeric: 1 < < 16 min., 2 15 to 30 min., 3 30 min. to 1 hour, or 4 >1 hour)
 14 studytime weekly study time (numeric: 1 < < 2 hours, 2 2 to 5 hours, 3 5 to 10 hours, or 4 >10 hours)
 15 failures number of past class failures (numeric: nif1 < =n<3, else 4)
 16 schoolsup extra educational support (binary: yes or no)
 17 famsup family educational support (binary: yes or no)
 19 activities extra-curricular activities (binary: yes or no)
 20 nursery attended nursery school (binary: yes or no)
 21 higher wants to take higher education (binary: yes or no)
 22 intern

- # these grades are related with the course subject, Math or Portuguese: 31 G1 first period grade (numeric: from 0 to 20)
- 31 G2 second period grade (numeric: from 0 to 20) 32 G3 final grade (numeric: from 0 to 20, output target)

6-2. 데이터의 기술통계치요약

데이터 기술통계치요약

•데이터:학생들의 학업성취도* (포루투칼의 고등학생 수학성적)

```
# lec6 2.r
# Data exploration : Numerical summary statistics
# set working directory
setwd("D:/tempstore/moocr")
### student math grade data ####
stud<-read.csv("stud math.csv")</pre>
head(stud)
dim(stud)
str(stud)
attach(stud)
```

stud 데이터는 n=395관측치와 33개의 변수

[1] 395 33 > str(stud) 'data.frame': 395 obs. of 33 variables: \$ school : Factor w/ 2 levels "GP", "MS":


1 ...

> dim(stud)

: Factor w/ 2 levels "F", "M": 1 \$ sex

• summary(데이터이름): 각 변수별로 요약통계량을 제공.

문자변수에 대해서는 빈도를 주고, 숫자변수에 대해서는 (최소값, 25%, 중위값, 평균, 75%, 최대값)을 제공




데이터 기술통계치요약

6-2. 데이터의 기술통계치요약

• mean(변수) : 평균

• sd(변수): 표준편차 (분산의 제곱근)

• var(변수) : 분산



통계함수	설명
mean(x)	평균
median(x)	중앙값
sd(x)	표준편차
mad(x)	Median absolute deviation
var(x)	분산



• 특정변수들에 대한 요약통계량 : vars<-c("변수1", "변수2", "변수3")

```
> vars<-c("G1", "G2", "G3")</pre>
# creating interested variable list
vars<-c("G1", "G2", "G3")
                                             head(stud[vars])
head(stud[vars])
                                             G1 G2 G3
summary(stud[vars])
                                              5
                                                5
                                                   6
                                              7
                                                8 10
                                           4 15 14 15
                                             6 10 10
                                           6 15 15 15
stud데이터는 33개의 변수를 가짐!!
                                           > summary(stud[vars])
=> 특정변수들에 대해 탐색하고자 할때
                                                  G1
                                                                 G2
                                                                                 G3
                                                                                : 0.00
                                                  : 3.00
                                                           Min.
                                                                 : 0.00
                                                                           Min.
                                            1st Qu.: 8.00
                                                           1st Qu.: 9.00
                                                                           1st Qu.: 8.00
                                            Median :11.00
                                                            Median :11.00
                                                                           Median :11.00
                                            Mean :10.91
                                                            Mean :10.71
                                                                           Mean :10.42
                                            3rd Qu.:13.00
                                                            3rd Qu.:13.00
                                                                           3rd Qu.:14.00
                                                   :19.00
                                                                                  :20.00
                                                                  :19.00
                                            Max.
                                                            Max.
                                                                           Max.
```



POSTECH

. 6-2. 데이터의 기술통계치요약

데이터 기술통계치요약


•함수 describe를 사용한 데이터요약통계량 (psych 패키지 필요)

```
# descriptive statistics using "psych" package
install.packages("psych")
library(psych)
# require "psych" for "describe" function
describe(stud[vars])
                                         > describe(stud[vars])
                                                  n mean sd median trimmed mad min max range
                                                                                                   skew
                                         G1
                                               1 395 10.91 3.32
                                                                    11
                                                                         10.80 4.45
                                                                                      3 19
                                                                                                  0.24
                                                                         10.84 2.97
                                                                                      0 19
                                                                                               19 -0.43
                                         G2
                                               2 395 10.71 3.76
                                                                    11
                                               3 395 10.42 4.58
                                                                         10.84 4.45
                                                                                               20 -0.73
                                            kurtosis
                                                       se
                                         G1
                                               -0.71 0.17
                                         G2
                                                0.59 0.19
                                                0.37 0.23
                                         G3
  sapply함수를 사용
# sapply function
                                  > sapply(stud[vars], mean)
sapply(stud[vars], mean)
                                                G2
                                  10.90886 10.71392 10.41519
```

• 범주형 변수의 요약: table(변수이름)

```
# categorical data
table(health) > table(health)
health
1 2 3 4 5
47 45 91 66 146
```

막대그림 (이름주기)






9

데이터 기술통계치요약

6-2. 데이터의 기술통계치요약

• 범주형 변수의 요약 : table(변수1, 변수2)

2*2 분할표







Wk6-3: 그래프를 이용한 데이터탐색

POSTECH

ⓒ포항공대 산업경영공학과 이혜선

데이터 설명

6-3. 그래프를 이용한 데이터탐색

• stud_math 데이터 : 포루투칼의 고등학생 수학성적 (stud_math_desc.doc참고)

school: 학교이름 (GP, MS)

sex : 성별 (F, M) age: 나이 (15-22)

address: 주소 (Urban:도심, Rural:외곽) famsize: 가족수 (LE3:≤3, GT3:>3)

Medu: 엄마교육수준 Fedu: 아빠교육수준

traveltime: 통학시간: 1(15분이하),2,3,4(1시간이상)

studytime: 주중공부시간: 1(<2시간), 2(2-5시간), 3(5-10시간),

4(>10시간)

activties : 방과후활동(yes, no), freetime : 자유시간(1-5)

nursery:유치원다녔는지여부(yes,no) internet: 집에서 인터넷사용(yes,no) romantic: 이성교제여부(yes, no) soout : 친구들과 외출 (1-5)

Dalc : 음주(1-5)

health: 건강상태 (1(매우나쁨)-5(매우좋음))

absences : 학교결석 (0-93)

타겟변수: G3(최종성적, 0-20), G2(2학년), G1(1학년)

Attribute Information:

Attributes for both student-mat.csv (Math course) and student-por.csv (Portuguese language course) datasets:

1 school - student's school (binary: 'GP' - Gabriel Pereira or 'MS' - Mousinho da Silveira)

2 sex - student's sex (binary: 'F - female or 'M' - male)

3 age - student's sex (binary: 'F - female or 'M' - male)

4 address - student's home address type (binary: 'U' - urban or 'R' - rural)

5 famsize - family size (binary: 'LE3' - less or equal to 3 or 'GT3' - greater than 3)

6 Pstatus - parent's cohabitation status (binary: 'T - iving together or 'A' - apart)

7 Medu - mother's education (numeric: 0 - none, 1 - primary education (4th grade), 2 &E' 5th to 9th grade, 3 &E' secondary educ

8 Fedu - father's education (numeric: 0 - none, 1 - primary education (4th grade), 2 &E' 5th to 9th grade, 3 &E' secondary educ

9 Mjob - mother's job (nominal: 'teacher', health' care related, civil 'services' (e.g. administrative or police), 'at_home' or 'other')

10 Fjob - father's job (nominal: 'teacher', health' care related, civil 'services' (e.g. administrative or police), 'at_home' or 'other')

11 reason - reason to choose this school (nominal: close to 'home', school 'reputation', 'course' preference or 'other')

12 guardian - student's guardian (nominal: 'mother', 'father' or 'other')

13 traveltime - home to school travel time (numeric: 1 -<15 min., 2 - 15 to 30 min., 3 - 30 min. to 1 hour, or 4 ->10 hours)

15 failures - number of past class failures (numeric: 1 -<2 hours, 2 - 2 to 5 hours, 3 - 5 to 10 hours, or 4 ->10 hours)

16 schoolsup - extra educational support (binary: yes or no)

17 famsup - family educational support (binary: yes or no)

18 paid - extra educational support (binary: yes or no)

18 paid - extra paid classes within the course subject (Math or Portuguese) (binary: ye 19 activities - extra-curricular activities (binary: yes or no) 20 nursery - attended nursery exhool (binary: yes or no) 21 higher - wants to take higher education (binary: yes or no) 22 internet - Internet access at home (binary: yes or no) 23 romantic - with a romantic relationship (binary: yes or no) 23 romantic - with a romantic relationship (binary: yes or no) 24 farmer - quality of family relationships (numeric: from 1 - very bad to 5 - excellent) 25 freetime - free time after school (numeric: from 1 - very low to 5 - very high) 26 goout - going out with friends (numeric: from 1 - very low to 5 - very high) 27 Dalc - workday alcohol consumption (numeric: from 1 - very low to 5 - very high) 29 health - current health status (numeric: from 1 - very low to 5 - very high) 30 absences - number of school absences (numeric: from 0 to 93)

these grades are related with the course subject, Math or Portuguese 31 G1 - first period grade (numeric: from 0 to 20)

31 G2 - second period grade (numeric: from 0 to 20)
32 G3 - final grade (numeric: from 0 to 20, output target)

POSTECH

그래프를 이용한 데이터탐색

• 히스토그램 (1학년, 2학년, 3학년 성적의 분포)

```
# lec6_3.r
# Normality test, confidence interval


# set working directory
setwd("D:/tempstore/moocr")

### student math grade data ####

stud<-read.csv("stud_math.csv")
head(stud)
dim(stud)
str(stud)

attach(stud)

# 1. histogram with color and title, legend
par(mfrow=c(2,2))
hist(G1, breaks = 10, col = "lightblue", main="Histogram of Grade 1" )
hist(G2, breaks = 10, col = "green", main="Histogram of Grade 2" )
hist(G3, breaks = 10, col = "coral", main="Histogram of Grade 3" )</pre>
```






그래프를 이용한 데이터탐색

6-3. 그래프를 이용한 데이터탐색

• 상자그림 (거주지역에 따른 G3, 통학시간에 따른 G3)

```
# 2. boxplot
par(mfrow=c(1,2))
boxplot(G3~address, boxwex = 0.5, col = c("yellow", "coral"), main="G3 by
boxplot(G3~traveltime, boxwex = 0.5, col = c("red", "orange", "yellow", "gree
```

- (1) 도심지역 학생들 성적이 외곽지역 학생들보다 높다
- (2) 통학시간이 짧은(15분이내)의 학생들의 성적이 더 높다




POSTECH
POHANG UNIVERSITY OF SCIENCE AND TECHNOLOGY


그래프를 이용한 데이터탐색

• 상자그림 (자유시간에 따른 G3, 공부시간에 따른 G3)

boxplot
par(mfrow=c(1,2))
academic achievement by freetime
1 - very low to 5 - very high
boxplot(G3~freetime, boxwex = 0.5, col = c("yellow", "green", "blue
academic achievement by studytime
1 - <2 hours, 2 - 2 to 5 hours, 3 - 5 to 10 hours, or 4 - >10 hou
boxplot(G3~studytime, boxwex = 0.5, col = c("yellow", "blue", "grey")

- (1) 방과후 자유시간에 따른 G3의 차이 : 자유시간이 적은편(low)이 라고 응답한 학생들의 성적이 다소 높은데..특별히 해석하기는 어려움
- (2) 주중공부시간이 5시간이상 (3: 5-10시간, 4: 10시간이상)인 학생 들의 성적이 높은편임





POSTECH

5


그래프를 이용한 데이터탐색

6-3. 그래프를 이용한 데이터탐색

• 통학시간과 최종성적(G3)의 멀티패널 그림 (성별): lattice 패키지 사용

lattice package
library(lattice)
xyplot(G3 ~ traveltime | sex , data = stud, pch=16, main = "G3 ~ travels")

- (1) 학생들 대부분은 30분이내의 통학거리에 있으며,
- (2) 통학거리가 짧은 학생들의 성적평균이 다소 높게 나타남
- (3) 통학거리가 1시간 이상은 표본이 상대적으로 적음





0점인 데이터 확인, 점검 필요

POSTELH

그래프를 이용한 데이터탐색

•G3=0인 데이터 (n=38명)





POSTELH
POHANG UNIVERSITY OF SCIENCE AND TECHNOLOGY


그래프를 이용한 데이터탐색

6-3. 그래프를 이용한 데이터탐색

• 산점도 (ggplot2 패키지의 ggplot이용)


```
# ggplot2 package
library(ggplot2)
# scatterplot for G1 and G3 by sex
ggplot(stud, aes(x=G1, y=G3, color=sex, shape=sex)) +
    geom_point(size=2)
```

성별에 따른 차이는 없음



POSTECH
POHANG UNIVERSITY OF SCIENCE AND TECHNOLOGY

그래프를 이용한 데이터탐색




POSTECH

6-3. 그래프를 이용한 데이터탐색

그래프를 이용한 데이터탐색

• pairwise scatterplot : pairs(변수리스트)

- (1) G1, G2, G3간의 상관성은 매우높다
- (2) 성별간 차이는 없다



Student Math Data





Wk6-4: 데이터의 정규성검정과 신뢰구간

POSTECH

ⓒ포항공대 산업경영공학과 이혜선

데이터 설명

6-4. 데이터의 정규성검정과 신뢰구간

• stud_math 데이터 : 포루투칼의 고등학생 수학성적 (stud_math_desc.doc참고)

school : 학교이름 (GP, MS)

sex : 성별 (F, M) age: 나이 (15-22)

address: 주소 (Urban:도심, Rural:외곽) famsize: 가족수 (LE3:≤3, GT3:>3)

Medu: 엄마교육수준 Fedu: 아빠교육수준

traveltime: 통학시간: 1(15분이하),2,3,4(1시간이상)

studytime: 주중공부시간: 1(<2시간), 2(2-5시간), 3(5-10시간),

4(>10시간)

activties : 방과후활동(yes, no), freetime : 자유시간(1-5)

nursery:유치원다녔는지여부(yes,no) internet: 집에서 인터넷사용(yes,no) romantic: 이성교제여부(yes, no) soout : 친구들과 외출 (1-5)

Dalc: 음주(1-5)

health: 건강상태 (1(매우나쁨)-5(매우좋음))

absences : 학교결석 (0-93)

타겟변수: G3(최종성적, 0-20), G2(2학년), G1(1학년)

Attribute Information:

Attributes for both student-mat csv (Math course) and student-por.csv (Portuguese language course) datasets:

1 school - student's sex (binary: "GP' - Gabriel Pereira or "MS' - Mousinho da Silveira)

2 sex - student's sex (binary: "F - female or "M' - male)

3 age - student's sex (binary: "F - female or "M' - male)

4 address - student's home address type (binary: "U' - urban or "R' - rural)

5 famsize - family size (binary: "LE3' - less or equal to 3 or "GT3' - greater than 3)

6 Pstatus - parent's cohabitation status (binary: "T - living together or "A' - apart)

7 Medu - mother's education (numeric: 0 - none, 1 - primary education (4th grade), 2 4€" 5th to 9th grade, 3 4€" secondary educe

8 Fedu - father's education (numeric: 0 - none, 1 - primary education (4th grade), 2 4€" 5th to 9th grade, 3 4€" secondary educe

9 Mjob - mother's job (nominal: 'teacher', health' care related, civil 'services' (e.g. administrative or police), "at home" or 'other')

10 Fjob - father's job (nominal: 'teacher', health' care related, civil 'services' (e.g. administrative or police), "at home" or 'other')

11 reason - reason to choose this school (nominal: close to 'home', 'school 'reputation', 'course' preference or 'other')

12 guardian - student's guardian (nominal: 'mother', 'father' or 'other')

13 traveltime - home to school travel time (numeric: 1 -<15 min., 2 - 15 to 30 min., 3 - 30 min. to 1 hour, or 4 ->10 hours)

15 failures - number of past class failures (numeric: 1 -<2 hours, 2 - 2 to 5 hours, 3 - 5 to 10 hours, or 4 ->10 hours)

16 schoolsup - extra educational support (binary: yes or no)

17 famsup - family educational support (binary: yes or no)


19 activities - extra -curricular activities (binary: yes or no)

18 paid - extra paid classes within the course subject (Math or Portuguese) (binary: ye 19 activities - extra-curricular activities (binary: yes or no) 20 nursery - attended nursery exhool (binary: yes or no) 21 higher - wants to take higher education (binary: yes or no) 22 internet - Internet access at home (binary: yes or no) 23 romantic - with a romantic relationship (binary: yes or no) 23 romantic - with a romantic relationship (binary: yes or no) 24 farmet - quality of family relationships (numeric: from 1 - very bad to 5 - excellent) 25 freetime - free time after school (numeric: from 1 - very low to 5 - very high) 26 goout - going out with friends (numeric: from 1 - very low to 5 - very high) 27 Dalc - workday alcohol consumption (numeric: from 1 - very low to 5 - very high) 28 Walc - weekend alcohol consumption (numeric: from 1 - very bow to 5 - very high) 30 absences - number of school absences (numeric: from 0 to 93)

31 G2 - second period grade (numeric: from 0 to 20)
32 G3 - final grade (numeric: from 0 to 20, output target)


데이터의 정규성검정

•정규확률도 (Normal Q-Q plot) : 데이터가 정규분포하는가?



qqline의 디폴트는 정규분포의 1사분위, 3사분위를 직선

qqline(y, distribution = qqnorm, probs = c(0.25, 0.75))




POSTECH

데이터의 정규성검정

6-4. 데이터의 정규성검정과 신뢰구간

- 정규분포(Normal distribution)
 - 확률변수 X 의 확률밀도함수가 다음과 같이 주어질 때 X 는 정규분포 $N(\mu, \sigma 2)$ 을 따른다고 함

$$f(x) = \frac{1}{\sqrt{2\pi}\sigma} e^{-\frac{(x-\mu)^2}{2\sigma^2}}, \quad -\infty < x < \infty$$



μ±σ에 대한 설명

(예) 중1학년 평균신장 150cm, 편차가 5cm라고하면

1시그마범위: 150±5 => (145cm-155cm)

2시그마범위: 150±10 => (140cm-160cm)

3시그마범위: 150±15 => (135cm-165cm)

어떤 학생의 신장이 $167 \mathrm{cm}$ 이면 그학생의 신장은 $\pm 3 \sigma$

를 벗어나 있다라고 말할수 있음

POSTECH

데이터의 정규성검정

•정규분포 적합성검정: 데이터가 정규분포 하는지에 대한 검정

(1) Shapiro-Wilks검정

```
#Shapiro-Wilks test
shapiro.test(G3)

Shapiro-Wilk normality test

G3는 정규분포한다고 볼수없다 (p-value~0)

#Shapiro.test(G3)

Shapiro-Wilk normality test

data: G3
W = 0.92873, p-value = 8.836e-13
```

(2) Anderson-Darling검정 (추가패키지 필요)

```
#Anderson-Darling test require installing package "nortest"
install.packages('nortest')
library(nortest)
ad.test(G3)

Anderson-Darling normality test

data: G3
A = 8.3032, p-value < 2.2e-16
```

G3는 정규분포한다고 볼수없다 (p-value~0)



5

데이터 시뮬레이션

6-4. 데이터의 정규성검정과 신뢰구간

•확률분포함수로부터 데이터생성

분포함수	설명
binom(x)	이항분포 rbinom(5, size=100,prob=.2)
exp(x)	지수분포
gamma(x)	감마분포 rgamma(5, shape=3, rate=2)
norm(x)	정규분포 rnorm(50, mean=10, sd=5)
pois(x)	포아송분포 rpois(n, lambda)
unif(x)	균일분포 runif(30)

p: 누적함수

d : 확률밀도함수

q : quantile 함수

r: 랜덤넘버의 생성

POSTELH
POHANG UNIVERSITY OF SCIENCE AND TECHNOLOGY

데이터 시뮬레이션

• 확률분포함수로부터 데이터생성

```
# data simulation
# Simulation examples
runif(5,min=1,max=5)
rnorm(5,mean=5,sd=1)
rgamma(5,shape=3,rate=2)
rbinom(5,size=100,prob=.2)
```



```
> runif(5,min=1,max=5)
[1] 3.001213 4.377249 3.358988 3.343567 2.458019
> rnorm(5,mean=5,sd=1)
[1] 4.454306 5.583966 6.178074 5.799947 5.294765
> rgamma(5,shape=3,rate=2)
[1] 1.496415 1.206023 1.987550 1.623255 1.513995
> rbinom(5,size=100,prob=.2)
[1] 25 18 23 19 18
```



_


데이터 시뮬레이션

6-4. 데이터의 정규성검정과 신뢰구간

•정규분포로부터 데이터생성, 밀도함수 그래프

from normal distribution
k<-rnorm(1000)
plot(density(x),xlim=c(-5,10))</pre>






POSTREH

데이터 시뮬레이션

• 데이터 생성 (정규분포(평균=500, 편차=100)에서 100개 데이터 생성)

```
# confidence interval of normal distribution
nreps <- 100
11 <- numeric(nreps)</pre>
ul <- numeric(nreps)</pre>
n <- 100
mu <- 500
sigma <- 100
for(i in 1:nreps) {
 set.seed(i)
  x <- rnorm(n, mu, sigma)
 ll[i] \leftarrow mean(x) - qnorm(0.975)*sqrt(sigma^2/n)
 ul[i] \leftarrow mean(x) + qnorm(0.975)*sqrt(sigma^2/n)
# Draw 95% confidence interval
par(mfrow=c(1,1))
plot(1:100, ylim=c(min(ll), max(ul)),
     ylab="95% Confidence Interval", xlab="iterations")
for(i in 1:100) lines(c(i, i), c(ll[i], ul[i]))
abline(h=mu, col="red", lty=2, lwd=3)
```






9

신뢰구간

6-4. 데이터의 정규성검정과 신뢰구간

- 신뢰구간
- 신뢰구간은 실제 모수(parameter=모평균, 모분산 등)를 추정하는데 몇 퍼센트의 확률로 그 신뢰구간이 실제 모수를 포함하게 될 것이냐 하는 것이다. 예를 들어 모평균(μ)의 추정을 위해 100번의 sampling을 통해 표본평균과 표본분산을 구하여 100개의 신뢰구간을 얻었을 때, 그 100개의 신뢰구간 중 95개에 모평균(μ)이 포함되게 설정된 신뢰구간을 95% 신뢰구간이라고 한다.





신뢰구간의 의미

- 신뢰수준, 표본오차
 - " 전국의 유권자 1,500명을 조사한 결과에 의하면 A 후보 지지율은 45%이며, 95% 신뢰수준에서 오차한계는 3.5%이다."

==> 지지도에 대한 95% 신뢰구간 : 표본 지지율±오차한계 ⇔ 45%±3.5% ⇔ (41.5%, 48.5%)

(예) A후보자 득표율 24% (허용오차 ±2%, 95% 신뢰수준)이라고 하면,그 의미는 n명을 표본으로 하여 random 하게 반복 조사하였을 때100번 중 95번은 22%-26% 득표율을 가질 것이라는 의미






	R을 이용한 통계분석 (Week7)	
wk7-1	두 그룹간 평균비교(t-test)	
wk7-2	짝을 이룬 그룹간 비교(paired t-test)	
wk7-3	분산분석(ANOVA)	
wk7-4	이원분산분석(two-way ANOVA)	



7-1. 두그룹간 평균비교(t-test)

Wk7-1: 두그룹간 평균비교 (t-test)

모집단간 차이에 대한 검정 (모수/비모수 검정)




1. 단일표본의 평균검정

7-1. 두그룹간 평균비교(t-test)

•단일표본의 평균검정: t.test(변수, mu=검정하고자 하는 평균값)


가설 1: G3(최종성적)의 평균은 10인가? H_0 (null Hypothesis: 귀무가설) : μ =10



2. 두 집단의 평균검정

• 두집단 표본평균 비교검정: t.test(타겟변수~범주형변수, data=)

가설 2: 거주지역(R, U)에 따른 G3(최종성적) 평균에 차이가 있는가? (양측검정)



POSTECH POHANG UNIVERSITY OF SCIENCE AND TECHNOLOGY

5

2. 두 집단의 평균검정

7-1. 두그룹간 평균비교(t-test)


• 두집단 표본평균 비교검정: t.test(연속변수~범주형변수, data=)

단측검정: 기각역이 한쪽에만 있는 경우, alternative=c("less") 혹은 alternative=c("greater")

```
H_0: \mu_R = \mu_U (\mu_R - \mu_U = 0)
# alternative H : mu(Rural) < mu(Urban)</pre>
t.test(G3~address, data=stud, alternative = c("less"))
                                                              H_1: \mu_R < \mu_U (\mu_R - \mu_U < 0)
help(t.test)
                                              > t.test(G3~address, data=stud, alternative = c("less"))
                                                       Welch Two Sample t-test
                                               data: G3 by address
                                               t = -2.1101, df = 140.91, p-value = 0.01831
                                               alternative hypothesis: true difference in means is less than 0
                                               95 percent confidence interval:
   p-value=0.018로 유의수준을 0.05로 했을때
                                                      -Inf -0.2504199
   성적(Rural)<성적(Urban)이라고 할수 있다
                                               sample estimates:
                                               mean in group R mean in group U
                                                      9.511364
                                                                     10.674267
```

2. 두 집단의 평균검정

• 두집단 표본평균 비교 도움말 보기 : help(t.test)




2. 두 집단의 평균검정

7-1. 두그룹간 평균비교(t-test)

• 두집단 표본평균 비교검정: t.test(타겟변수~범주형변수, data=)

가설 3: 방과후 활동여부(yes, no)에 따른 G3(최종성적) 평균에 차이가 있는가?




POSTREH

2. 두 집단의 평균검정

• 두집단 표본평균 비교검정: t.test(타겟변수~범주형변수, data=)

가설 3: 방과후 활동여부(yes, no)에 따른 G3(최종성적) 평균에 차이가 있는가?

t-test 검정통계량에 의한 검정결과



p-value=0.75는 유의수준 0.05보다 큽니다. 즉 검정통계량의 값이 기각역에 있지 않다.

- => 귀무가설(평균이같다)를 기각할수 없음
- => 방과후활동여부는 G3에 유의한 영향이 없다!

평균(G3(방과후활동없음)-G3(방과후활동)) 차이에 대한 신뢰구간 = (-1.05, 0.79)

신뢰구간 사이에 0값이 있다는것은 차이가 없음을 의미!!



3. 두 집단의 비모수적 비교검정

7-1. 두그룹간 평균비교(t-test)

•두 모집단의 비모수적 방법 (Wilcoxon rank sum Test) : wilcox.test(x,y)

wilcox.test는 타겟변수가 등간척도(통증정도, 만족도, ..)일때 사용할 수 있다

```
> wilcox.test(G3~address)
  # Wilcoxon signed-rank test
  # wilcox.test(G3, mu=10)
                                                      Wilcoxon rank sum test with continuity correction
 wilcox.test(G3~address)
                                             data: G3 by address
                                             W = 11278, p-value = 0.01776
  wilcox.test(타겟변수~범주형변수)
                                             alternative hypothesis: true location shift is not equal to 0
                                             Wilcoxon Rank Sum and Signed Rank Tests
                                             Description
                                             Performs one- and two-sample Wilcoxon tests on vectors of data; the latter is also known as 'Mann-Whitney'
    help(wilcox.test)
                                             Usage
                                             wilcox.test(x, ...)
                                             ## Default S3 method:
                                             wilcox.test(x, y = NULL,
                                                       alternative = c("two.sided", "less", "greater"),
mu = 0, paired = FALSE, exact = NULL, correct = TRUE,
POSTECH
                                                        conf.int = FALSE, conf.level = 0.95, ...)
```




Wk7-2: 짝을 이룬 그룹간 비교 (paired t-test)


POSTECH

ⓒ포항공대 산업경영공학과 이혜선

모집단간 차이에 대한 검정 (모수/비모수 검정)



- 특정 처리(treatment)의 효과를 비교분석할 때 사용
- 동일한 실험표본: before & after 측정



예제:

- (1)혈압강하제의 투약효과
- (2) 방과후프로그램의 성과 (학업흥미도)
- (3)다이어트 프로그램의 효과
- (4) 직무교육후의 생산성 향상의 효과

평균, 편차 계산=> 검정통계량




3

짝을 이룬 그룹간 비교 (paired t-test)

7-2. 짝을 이룬 그룹간 비교(paired t-test)

예제 1 : 고혈압 환자 10명에게 혈압강하제를 12주동안 투여한 후 복용전의 혈압과 복용후의 혈압을 비교하였다. 새로운 혈압강하제가 효과가 있다고 할수 있는가?





짝을 이룬 그룹간 비교 (paired t-test)

paired t-test : t.test(before, after, mu=0, paired=T))

```
# lec7_2.r

# paired t-test for two sample means

# set working directory
setwd("D:/tempstore/moocr")

## example 1: blood pressure data
bp<-read.csv("bp.csv")
attach(bp)

# paired t-test (two-sided)
t.test(bp_pre, bp_post, mu=0, paired=T)</pre>
```

p-value=0.0015 (매우 작음) 유의수준 0.05 (α =0.05)보다 작으므로 H_0 를 기각=> 따라서 투약전과 투약후의 혈압에 유의한 차이가 있다고 볼 수 있음

POSTECH

```
양측검정 : H_0 : \mu_{\text{(dif)}} = 0, H_1 : \mu_{\text{(dif)}} \neq 0 유의한 차이가 있는지 없는지에 대한 검정
```

```
> t.test(bp_pre, bp_post, mu=0, paired=T)

Paired t-test
t검정통계량, 자유도, p-value

data: bp_pre and bp_post
t = 4.5095, df = 9, p-value = 0.001469
alternative hypothesis: true difference in means is not equal to 0
95 percent confidence interval:
7.226228 21.773772
sample estimates:
mean of the differences
14.5
```

7-2. 짝을 이룬 그룹간 비교(paired t-test)

짝을 이룬 그룹간 비교 (paired t-test)

• paired t-test의 검정통계량

```
> t.test(bp_pre, bp_post, mu=0, paired=T)

Paired t-test

t검정통계량, 자유도, p-value

data: bp_pre and bp post

t = 4.5095, df = 9, p-value = 0.001469

alternative hypothesis: true difference in means is not equal to 0

95 percent confidence interval:
 7.226228 21.773772

sample estimates:
mean of the differences

14.5
```

t=4.5095 =
$$\frac{(평균(Dif))-0}{
ੁ 편차_{(Dif)/\sqrt{n}}} = \frac{14.5-0}{10.168/\sqrt{10}}$$



paired t-test: t.test(before, after, mu=0, alternative="greater", paired=T))

단측검정 : H_0 : $\mu_{(dif)} = 0$, H_1 : $\mu_{(dif)} > 0$ 혈압(투약전-투약후)의 차이가 0보다 큰가?

p-value=0.0007 (매우 작음)
 유의수준 0.05 (α=0.05)보다 작으므로
 H₀ 를 기각=> 따라서 투약효과가 매우
 유의하다고 볼 수 있다 (즉, 투약전보다
 투약후의 혈압이 유의하게 낮아진다는
 것이 검정됨)



7

1. 짝을 이룬 그룹간 비교 (paired t-test)

7-2. 짝을 이룬 그룹간 비교(paired t-test)

• 예제 2*: 비만 대상자들(성인)에게 12주동안 극저 칼로리 식이요법(very low-calorie diet: VLCD)을 실시한 후 그 효과를 비교. 이 프로그램이 체중감소에 효과가 있다고 할수 있는가?

weight.csv

A	В	С
id	wt_pre	wt_post
1	117.3	83.3
2	111.4	85.9
3	98.6	75.8
4	104.3	82.9
5	105.4	82.3
6	100.4	77.7
7	81.7	62.7
8	89.5	69
9	78.2	63.9

very low-calorie** <=800 calories/day

low-calorie

1,000-1,200 calories/day for a woman 1,200-1,600 calories/day for a man

standard-calorie

2000 calories/day



^{*} 박미라, 이재원, 의학데이터의 통계분석, 자유아카데미

^{*} https://www.niddk.nih.gov/health-information/weight-management/very-low-calorie-diets

• 예제 2 : 극저 칼로리 식이요법(very low-calorie diet: VLCD)의 효과

```
## example 2: Very Low-calroie diet
diet<-read.csv("weight.csv")
attach(diet)

# paired t-test (two-sided)
t.test(wt_pre, wt_post, mu=0, paired=T)</pre>
```

```
양측검정 : H_0 : \mu_{\rm (dif)} = 0, H_1 : \mu_{\rm (dif)} \neq 0
극저칼로리 식이요법이 체중감량에 유의한 효과가
있는지 없는지에 대한 검정
```

참고 : 0.001을 1e-3으로도 표기





Wk7-3: 분산분석 (ANOVA)

- Analysis of Variance -




ⓒ포항공대 산업경영공학과 이혜선

1. 분산분석의 개념

7-3. 분산분석(ANOVA)

• ANOVA (Analysis of Variance) : 전체분산(variance)을 분할(분석, analysis)하여 어떤 요인(factor)의 영향이 유의한지(significant)한지 검정하는 방법.

(예) Drug effect (5mg, 10mg, placebo) Age effect(young, old)



factor가 1개일때의 분산분석모형


$$y_{ij} = \mu + \tau_i + \varepsilon_{ij}, \begin{cases} i = 1, 2, ..., a \\ j = 1, 2, ..., n \end{cases}$$

 μ = an overall mean, τ_i = ith treatment effect, ε_{ij} = experimental error, $N(0, \sigma^2)$

7-3. 분산분석(ANOVA)

2. 분산분석 : factor가 한개일때

- •분산분석모형 적용
- (1) 거주지역에 따른 학업성취도 : 거주지역(factor: R/U), 학업성적(1-20)
- (2) 통학시간에 따른 학업성취도 : 통학시간(factor: 1-4), 학업성적(1-20)



2. 분산분석 : factor가 한개일때

7-3. 분산분석(ANOVA)

(1) 거주지역에 따른 학업성취도 : 거주지역(factor: R/U), 학업성적(1-20)

가설1: 거주지역(R/U)에 따라 G3에 유의한 영향이 있나?

aov(타겟변수~factor)

```
# ANOVA
a1 <- aov(G3~address)
summary(a1)
```


p-value=0.035. 유의수준을 0.05로 잡을때 0.05보다 작으므로=> 거주지역에 따른 학업성적에는 유의한 차이가 있다고 할수 있음



2. 분산분석 : factor가 한개일때

(1) 거주지역에 따른 학업성취도 : 거주지역(factor: R/U), 학업성적(1-20)

G3 by (Urban, Rural)



분산분석 결과는 상자그림으로 본 거주지역에 따른 G3의 차이가 <u>통계적으로 유의하다는</u> 것을 보여줌!!



5


2. 분산분석 : factor가 한개일때

7-3. 분산분석(ANOVA)

(2) 통학시간에 따른 학업성취도 : 통학시간(factor: 1-4), 학업성적(1-20)

가설2: 통학시간에 따라 G3에는 유의한 차이가 있나?

aov(타겟변수~factor)



- p-value=0.139, 유의수준을 0.05로 잡을때 0.05보다 크므로=> 유의수준
 0.05에서는 통학시간에 따른 학업성적에는 유의한 차이 없다고 할수 있다
- 그러나 p-value가 0.139이므로 어느정도 차이가 존재함을 알수 있다.

G3 by traveltime

POSTELH
POHANG UNIVERSITY OF SCIENCE AND TECHNOLOGY

3. 사후검정(post-hoc analysis)

• 사후검정: ANOVA에서 어떤 factor의 유의성이 검정되면, 그 다음단계에 하는 검정

Tukey's Honest Significant Difference Test


should be foctor for Tukey's Honest Sig TukeyHSD(a2, "traveltime", ordered=TRUE) plot(TukeyHSD(a2, "traveltime"))

- μ_1 - μ_2 =0이라는 의미는 1그룹과 2그룹간 차이가 없다는 의미

TukeyHSD (a2, "traveltime", ordered=TRUE) Tukev multiple comparisons of means 95% family-wise confidence level factor levels have been ordered Fit: aov(formula = G3 ~ traveltime) Straveltime diff lwr upr 3-4 0.5108696 -4.3256048 5.347344 0.9929165 2-4 1.1565421 -3.1623166 5.475401 0.9005404 1-4 2.0321012 -2.1981712 6.262374 0.6021367 2-3 0.6456725 -2.0624782 3.353823 0.9272302 1-3 1.5212316 -1.0432848 4.085748 0.4202138 1-2 0.8755591 -0.4800959 2.231214 0.3429618

95% 신뢰구간의 lower bound, upper bound

95% family-wise confidence leve



Differences in mean levels of traveltime

모든 pairwise 신뢰구간 에 0이 포함됨 => 유의한 차이가 없음

POSTREH


7-3. 분산분석(ANOVA)

4. 추가예졔: 분산분석

(4) 연애경험여부에 따른 학업성취도 : 연애경험(yes, no), 학업성적(1-20)

```
# 4. ANOVA by romantic
a4 <- aov(G3~romantic)
summary(a4)
# tapply - give FUN value by address
round(tapply(G3,romantic, mean),2)
```

G3 by romantic



- 연애경험이 있는 경우 학업성적이 유의하게 낮음 (p-value=0.0097)
- median은 비슷해보이지만, 평균은 10.84-9.58=1.26 차이있음



Wk7-4: 이원분산분석 (two-way ANOVA)




ⓒ포항공대 산업경영공학과 이혜선

7-4. 이원분산분석(two-way ANOVA)

이원분산분석 (two-way ANOVA)

• ANOVA (Analysis of Variance) : 전체분산(variance)을 분할(분석, analysis)하여 어떤 요인(factor)<mark>의 영향이 유의한지(significant)한지 검정하는 방법.</mark>

(예) Drug effect (5mg, 10mg, placebo) Age effect(young, old)



전체변동(전체분산)=:
$$\sum_{i=1}^{a} \sum_{j=1}^{b} (Y_{ij} - \overline{Y}_{..})^2$$



이원분산분석 (two-way ANOVA)

• 데이터 : High-Density Lipoprotein (HDL) 콜레스테롤

chol_ex.csv

1. ID

2. drug: 5mg, 10mg, placebo

3. age : young(18-39), old (≥40세)

4. value: HDL(투약전)-HDL(투약후)

id	drug	age	value
1	placebo	young	4
2	placebo	young	3
3	placebo	young	-1
4	placebo	old	3
5	placebo	old	1
6	placebo	old	2
7	5mg	young	7
8	5mg	young	5
9	5mg	young	6
10	5mg	old	5
11	5ma	old	7

*HDL(고밀도 리포 단백질)은 높을수록 좋은것으로 알려진 콜레스테롤. 40mg/dl이상이 정상범위



.

이원분산분석 (two-way ANOVA)

7-4. 이원분산분석(two-way ANOVA)

- •이원분산분석 (two-way ANOVA): factor가 두개인 경우
 - (1) 투약효과가 있는가? (5mg, 10mg, 위약)
 - (2) 연령그룹(young/old)에 따른 영향이 있는가?

가설 1: 신약의 투약효과가 있는가? HDL을 상승시키는 효과가 있나?

가설 2: 연령그룹에 따라 투약효과(HDL변화)에 차이가 있나?

가설 3: 신약의 투약과 연령그룹간 상호작용 효과가 있는가?

POHANG UNIVERSITY OF SCIENCE AND TECHNOLOGY

이원분산분석 (two-way ANOVA)

•이원분산분석: aov(타겟변수~factor1+ factor2)

lec7_3.R > a6 <- aov(value ~ drug + age) dat<-read.csv(file="chol ex.csv")</pre> > summary(a6) head(dat) Df Sum Sq Mean Sq F value dim(dat) 80.72 33.568 4.55e-06 *** drua 2 161.44 str(dat) age 4.50 4.50 1.871 0.193 attach(dat) 33.67 2.40 Residuals 14 # two-way ANOVA, Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' a6 <- aov(value ~ drug + age) summary(a6)

- (1) drug effect : p-value~0이므로 HDL값에 <u>통계적으로 유의한 차이가 있음</u>
- (2) age: p-value=0.19로 유의수준 0.05에서 유의한 차이는 없음



5

이원분산분석 (two-way ANOVA)

7-4. 이원분산분석(two-way ANOVA)

•이원분산분석: aov(타겟변수~factor1+ factor2+ 상호작용)

두개의 factor간 상호작용의 유의성을 검정하기 위한 분석

```
> a7 <- aov(value ~ drug + age+ drug*age)</pre>
# two-way ANOVA with interaction
                                                   summary(a7)
a7 <- aov(value ~ drug + age+ drug*age)
                                                              Df Sum Sq Mean Sq F value
                                                                                           Pr(>F)
summary(a7)
                                                 drug
                                                               2 161.44 80.72 35.439 9.21e-06 ***
                                                                                            0.185
                                                 age
                                                                   4.50
                                                                           4.50
                                                                                   1.976
                                                 drug:age
                                                               2
                                                                   6.33
                                                                           3.17
                                                                                   1.390
                                                                                            0.286
                                                 Residuals
                                                              12 27.33
                                                                           2.28
```

(3) drug와 age그룹간 상호작용 : p-value=0.286으로 유의수준 0.05에서 유의한 차이는 없음

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.

POSTECH
POHANG UNIVERSITY OF SCIENCE AND TECHNOLOGY

이원분산분석 (two-way ANOVA) : 두 요인의 상자그림

• 투약용량과 연령그룹에 따른 상자그림

```
# two-way ANOVA
par(mfrow=c(1,2))
boxplot(value ~ drug, boxwex = 0.7, main="HDL by drug dose", col = c("yellow","
boxplot(value ~ age, boxwex = 0.5, main="HDL by Age", col = c("blue", "coral"))
```


(1) drug effect: 10mg인 경우 HDL 상승효과가 가장 높음


tapply - give FUN value by drug
round(tapply(value, drug, mean),2)

> round(tapply(value, drug, mean),2)
 10mg 5mg placebo
 9.33 5.83 2.00

(2) age : young그룹(18-40)의 HDL 상승효과가 더 높음

> round(tapply(value, age, mean),2)
 old young
5.22 6.22






POSTECH

이원분산분석 (two-way ANOVA) : 상호작용 그래프

• 상호작용 그래프

interaction plot
par(mfrow=c(1,2))
interaction.plot(drug, age, value)
interaction.plot(age, drug, value)

- 투약용량 10mg에서 young그룹의 상승효과가 old그룹보다 훨씬 높음
- 5mg에서와 placebo에서는 연령그룹의 차이가 거의없음



(1) 투약용량을 기준(x축)으로 그릴때 (2) 연령그룹을 기준(x축)으로 그릴때



	단위별 학습내용 (Week8)	
wk8-1	상관분석	
wk8-2	회귀분석(선형모형)	
wk8-3	텍스트마이닝 I	
wk8-4	텍스트마이닝 II	



8-1. 상관분석

Wk8-1 : 상관분석

1. 상관분석 : 상관계수


• 상관계수 : cor(변수1, 변수2)

```
# lec7_4.r
# correlation coefficent

# set working directory
setwd("D:/tempstore/moocr")

# autompg data
car<-read.csv("autompg.csv")
#head(car)
#dim(car)|

# subset of car : cyl (4,6,8)
car1<-subset(car, cyl==4 | cyl==6 | cyl==8)
attach(car1)</pre>
```



cor의 디폴트는 pearson의 상관계수 kendall의 상관계수 혹은 spearman의 상관계수를 구할때는 cor(변수1, 변수2, method=c("spearman"))



8-1. 상관분석


1. 상관분석: 상관계수

• 상관계수와 산점도

```
# 6. pariwise plot
# new variable lists
vars1<-c("disp", "wt", "accler", "mpg")
# pariwise plot
pairs(car1[vars1], main = "Autompg", cex=1, col=as.integer(car1$c</pre>
```

(1) 차량무게와 배기량과는 정비례관계 (양의 상관계수)


- (2) MPG(연비)와 (wt, disp)는 상관성이 높다 (반비례 음의 상관계수)
- (3) cylinder별로 색으로 표시 (파란색:4, 진한핑크: 6, 회색 : 8)





POSTREH

2. 상관분석 - 상관계수와 산점도


• 상관계수(r)은 절대값이 0-1사이 값을 갖는다









- 절대값이 0에 가까울수록 상관관계가 없다
- 절대값이 1에 가까운수록 강한 상관성이 있다










5


3. 통계치와 그래프 : 주의!!

8-1. 상관분석

• 통계치와 그래프 - Monkey 데이터 + King Kong 한마리







monkey.csv

ID	height	weight
1	55	29
2	45	27
3	35	17
4	39	29
5	53	31
6	41	21
7	51	31
8	35	13
9	57	37
10	57	41
11	45	45
12	47	35
13	35	25
14	49	25
15	43	31
16	51	33
17	31	29
18	53	27
19	47	17
20	51	45



3. 통계치와 그래프 : 주의!!

• 통계치와 그래프 - Monkey 데이터 + King Kong 한마리

```
## Monkey data + Kingkong
monkey1<-read.csv("monkey_k.csv")
head(monkey1)
dim(monkey1)
attach(monkey1)</pre>
```

correlation coefficients
cor(height, weight)



> cor(height, weight)
[1] 0.940375

상관계수: 0.94



ID	height	weight
1	55	29
2	45	27
3	35	17
4	39	29
5	53	31
6	41	21
7	51	31
8	35	13
9	57	37
10	57	41
11	45	45
12	47	35
13	35	25
14	49	25
15	43	31
16	51	33
17	31	29
18	53	27
19	47	17
20	51	45
21	130	150



_

3. 통계치와 그래프: 주의!!

8-1. 상관분석

• 선형회귀식 - Monkey 데이터

```
# linear model and summary of linear model | m1<-lm(weight-height) | summary(m1) | Call: | lm(formula = weight ~ height) | lm(formula = weight) | lm(formula
```

```
lm(formula = weight ~ height)
Min 1Q Median
-12.9797 -5.7186 -0.2983
                                 3Q
                                         Max
                            3.9983 16.1797
            Estimate Std. Error t value Pr(>|t|)
            2.7356
                       10.2815 0.266
                                           0.793
             0.5797
                         0.2205
                                2.629
                                           0.017 *
Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
Residual standard error: 7.573 on 18 degrees of freedom
Multiple R-squared: 0.2775
                               Adjusted R-squared: 0.2374
F-statistic: 6.913 on 1 and 18 DF, p-value: 0.01702
```

POSTELH
POHANG UNIVERSITY OF SCIENCE AND TECHNOLOGY

3. 통계치와 그래프 : 주의!!

• 선형회귀식 - Monkey 데이터 + King Kong 한마리

```
> m2<-lm(weight~height)</pre>
 linear model and summary of linear model
                                               > summary(m2)
m2<-lm(weight~height)
summary (m2)
                                               Call:
                                               lm(formula = weight ~ height)
                                               Residuals:
                                                   Min
                                                            10 Median
                                               -14.219
                                                       -7.298
                                                               -2.372
                                                                        8.243
                                                                               18.706
                                               Coefficients:
                                                           Estimate Std. Error t value Pr(>|t|)
       선형회귀식
                                               (Intercept) -30.2495
                                                                        5.8203
                                                                               -5.197 5.13e-05 ***
       Y(weight) = -30.25 + 1.31X(height)
                                               height
                                                             1.3078
                                                                        0.1085 12.051 2.41e-10 ***
                                               Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
                                               Residual standard error: 9.646 on 19 degrees of freedom
                 선형회귀식의 결정계수 4
                                               Multiple R-squared: 0.8843,
                                                                              Adjusted R-squared: 0.8782
                                               F-statistic: 145.2 on 1 and 19 DF, p-value: 2.412e-10
                 R^2 = 0.88
```




8-1. 상관분석

3. 통계치와 그래프: 주의!!

• 통계치와 그래프 - Monkey 데이터 + King Kong 한마리

한마리의 킹콩 데이터가 몸무게와 신장의 상관관계에 대한 해석을 완전히 바꿔놓을수 있다!!

Monkey data + 1 King Kong





POSTECH
POHANG UNIVERSITY OF SCIENCE AND TECHNOLOGY

Wk8-2: 회귀분석 (선형모형)



ⓒ포항공대 산업경영공학과 이혜선

1

1. 회귀분석 - 데이터

8-2. 회귀분석 (선형모형)

• autompg 데이터

```
1. mpg: continuous (연비 : 연속형변수)
```

2. cylinders: multi-valued discrete (실린더 : 정수값)

3. displacement: continuous (배기량 : 연속형변수)

4. horsepower: continuous (마력 : 연속형변수)

5. weight: continuous (무게: 연속형변수)

6. acceleration: continuous (가속 : 연속형변수)

7. year: multi-valued discrete (모델연도 : 정수값)

8. origin: multi-valued discrete (정수값)

9. car name: string (unique for each instance) (차종류 이름)

```
# lec8_2.r : Linear model
# Regression

# set working directory
setwd("D:/tempstore/moocr")

# autompg data
car<-read.csv("autompg.csv")
head(car)
str(car)

# subset with cyl=4,6,8
car1<-subset(car, cyl==4 | cyl==6 | cyl==8)
attach(car1)</pre>
```



```
> car<-read.csv("autompg.csv")</pre>
> head(car)
 mpg cyl disp hp
                   wt accler year origin
                                                          carname
                       12.0
                                    1 chevrolet chevelle malibu
       8 307 17 3504
                              70
  18
          350 35 3693
                        11.5
                               70
                                               buick skylark 320
       8 318 29 3436
                                               plymouth satellite
                        11.0
                              70
                                     1
  18
  16
       8 304 29 3433
                        12.0 70
                                      1
                                                    amc rebel sst
       8 302 24 3449
                        10.5
  17
                              70
                                                      ford torino
          429 42 4341
                        10.0
                                                 ford galaxie 500
```



2. 회귀분석 - 단순회귀모형

• 단순회귀모형 : lm(y변수~x변수, data=)

```
# 1. simple Regression(independent variable : wt)
r1<-lm(mpg~wt, data=car1)
summary(r1)
anova(r1)</pre>
```

1. 단순회귀모형

종속변수: mpg(연비), 독립변수: wt(차량무게)

```
> r1<-lm(mpg~wt, data=car1)</pre>
> summary(r1)
lm(formula = mpg ~ wt, data = car1)
Residuals:
Min 10 Median 30 Max
-9.6770 -2.7567 -0.3636 2.1120 16.3712
                                                                          선형회귀식
                                                                          y(mpg) = 46.60 - 0.0077(wt)
               Estimate Std. Error t value Pr(>|t|)
(Intercept) 46.600189 0.779849 59.76 wt -0.007759 0.000252 -30.79
                                                <2e-16 ***
                                                <2e-16 ***
wt
Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
                                                                         ▶선형회귀식의 결정계수
Residual standard error: 4.239 on 389 degrees of freedom
Multiple R-squared: 0.709, Adjusted R-squared: 0.79, F-statistic: 947.9 on 1 and 389 DF, p-value: < 2.2e-16
                                    Adjusted R-squared: 0.7083
                                                                          R^2 = 0.71
```



2

2. 회귀분석 - 단순회귀모형

8-2. 회귀분석 (선형모형)


• 산점도에 회귀선 그리기

```
# (lec4_3.R) scatterplot with best fit lines
par(mfrow=c(1,1))
plot(wt, mpg, col=as.integer(car1$cy1), pch=19)
# best fit linear line
abline(lm(mpg~wt), col="red", lwd=2, lty=1)
```

plot(x축변수, y축변수)

abline : add line (선을 추가하는 함수)

lm(y변수~x변수): lm은 linear model(선형모형)의 약자




POSTEL POHANG UNIVERSITY OF SCIENCE AND TECHNOLOGY

3. 회귀분석의 목적

- •회귀분석의 목적:예측(prediction)과 추정(estimation)
 - 선형모형 : 독립변수와 종속변수간의 관계가 선형식으로 적합

모형 : $Y_i = \beta_0 + \beta_1 X_i + \epsilon_i$, i=1, 2, ..., n





8


4. 회귀분석 - 모형의 적합도

8-2. 회귀분석 (선형모형)

• 모형의 적합도와 결정계수 (R²): 0 ≤ R² ≤ 1

: 전체제곱합(SST)에 대한 회귀제곱합(SSR)의 비율, 즉 모형으로 설명할수 있는 부분의 비율

$$R^2 = \frac{SSR}{SST} = 1 - \frac{SSE}{SST}$$



전체제곱합의 분할: SST=SSR+SSE

전체제곱합(SST): $SST = \sum (Y_i - \overline{Y})^2$

회귀제곱합(SSR): $SSR = \sum (\hat{Y}_i - \overline{Y})^2$

잔차제곱합(SSE): $SSE = \sum (Y_i - \hat{Y}_i)^2$

4. 회귀분석 - 모형의 적합도

• 회귀식에 의해 설명되는 부분(SSR)과 설명되지 않는부분(SSE)

```
> anova (r1)
Analysis of Variance Table

Response: mpg

Df Sum Sq Mean Sq F value Pr(>F)

wt 1 17029.1 17029 947.87 < 2.2e-16 ***

Residuals 389 6988.6 18

R^2 = \frac{SSR}{SST} = \frac{17029}{24017} = 0.709
```

- R²는 1에 가까울수록 회귀식에 의해 적합되는 부분이 높음
- R²는 0에 가까우면 주어진 독립변수들에 의해 설명(예측 혹은 적합)되는 부분이 없다고 할 수 있다

SST=total sum of squares SSR=regression sum of squares SSE=error(residual) sum of squares



-

4. 회귀분석

8-2. 회귀분석 (선형모형)

```
# 2. simple Regression(independent variable : disp)
r2<-lm(mpg~disp, data=car1)
summary(r2)
anova(r2)</pre>
```

#2. 단순회귀모형

종속변수: mpg(연비), 독립변수: disp(배기량)

```
> summary(r2)
lm(formula = mpg \sim disp, data = car1)
Residuals:
     Min
               10 Median
                                 3<u>0</u>
                                         Max
-10.0627 -3.0037 -0.6113 2.3110 18.5978
            Estimate Std. Error t value Pr(>|t|)
(Intercept) 35.49479
                        0.48640 72.97 <2e-16 ***
            -0.06142
                        0.00220 -27.93
                                         <2e-16 ***
disp
Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 '
Residual standard error: 4.533 on 389 degrees of freedom
Multiple R-squared: 0.6672, Adjusted R-squared: 0.6663
F-statistic: 779.8 on 1 and \overline{3}89 DF, p-value: < 2.2e-16
```

선형회귀식


y(mpg) = 35.49 - 0.0614(disp)


선형회귀식의 결정계수 R²=0.67

5. 회귀분석 - 잔차의 산점도

•회귀분석의 가정과 진단

```
# residual diagnostic plot
layout(matrix(c(1,2,3,4),2,2)) # optional 4 graphs/page
plot(r2)
```





참고: 전치혁, 정민근, 이혜선, 공학응용통계, 홍릉출판사, 2012



6. 회귀분석

8-2. 회귀분석 (선형모형)

• 다중회귀분석 : 독립변수들이 여러 개인 경우

```
# 3. multiple Regression
r3<-lm(mpg~wt+accler, data=car1)
summary(r3)
anova(r3)</pre>
```

• pairwise scatterplot

```
# pariwise plot
# new variable lists
vars1<-c("disp", "wt", "accler", "mpg")
# pariwise plot
pairs(car[vars1], main ="Autompg",cex=1,</pre>
```



Wk8-3: 텍스트마이닝 I



1

1. 텍스트마이닝이란?

8-3. 텍스트마이닝 I

텍스트마이닝 (Text mining)

- 텍스트마이닝은 <u>웹페이지, 이메일, 소셜네트워크 기록</u>, 등 전자문서 파일로부터 특정 연관성(동시적으로 빈도가 높은 단어추출)을 분석하는 방법
- 텍스트마이닝은 다양한방식의 알 고리즘을 이용하여 대용량의 텍스 트문서로부터 <u>트렌드와 관심어</u>를 찾아내는 기법으로 사용



POSTELF POHANG UNIVERSITY OF SCIENCE AND TECHNOLOGY

2

2. 텍스트마이닝에 필요한 패키지

텍스트마이닝을 위한 패키지

자연어처리 install.packages("NLP") library(NLP)

텍스트마이닝 패키지 install.packages("tm") library(tm)

텍스트마이닝 결과의 시각화 install.packages("wordcloud") library(wordcloud)

그 외 패키지

한글처리를 위한 패키지
install.packages("KoNLP")
library(KoNLP)

트위터의 데이터를 불러오는 패키지
install.packages("twitteR")
library(twitteR)

color displaying
install.packages('RColorBrewer')
library(RColorBrewer)



3

2. 텍스트마이닝에 필요한 패키지

8-3. 텍스트마이닝 I

• 패키지설치와 라이브러리 설정, tm의 예제 데이터 (crude)

```
# 1ec8 3.R
# Install package NLP, tm, wordcloud
# set working directory
setwd("D:/tempstore/moocr")
# Natural language processing
install.packages('NLP')
# text mining package
install.packages('tm')
                                  텍스트마이닝을 위한 추가패키지 설치
# visualizing
install.packages('wordcloud')
# color displaying
install.packages('RColorBrewer'
# set library (set in order)
library (NLP)
library(tm)
                                   패키지의 라이브러리 설정
library(RColorBrewer)
library (wordcloud)
# 20 new articles from Reuter- 21578 data set
data(crude)
                                   tm에 포함된 데이터 crude사용
# To know about crude data
help(crude)
```

POSTECH

3. 텍스트마이닝 패키지(tm)의 데이터

• 예제데이터: crude* 데이터 (로이터통신의 20개의 뉴스기사)

crude[[1]]: 첫번째 기사 (아래와 같은 XML파일 형태로 저장)- tm패키지에 들어있는 예제데이터

```
C:WUserswhyeseon#DocumentswRwini-library#3.4\tmm\text{rm}. \(P \times \) \(\delta \) \(\de
파일(F) 편집(E) 보기(V) 즐겨찾기(A) 도구(T) 도움말(H)
       <EXCHANGES/>
                          COMPANIES/
                          UNKNOWN>Y f0119 reute u f BC-DIAMOND-SHAMROCK-(DIA 02-26 0097</UNKNOWN>
```

*Reuters-21578 text categorization test collection Distribution 1.0 README file (v 1.2), 1987년의 뉴스기사



4. 텍스트마이닝 예제 : Crude(원유)데이터

lec8 3.R

```
set library (set in order)
library(NLP)
library(tm)
library(RColorBrewer)
library (wordcloud)
# 20 new articles from Reuter- 21578 data set
data(crude)
 To know about crude data
help(crude)
# remove punctuation in documnet
crude <- tm_map(crude, removePunctuation)
 remove stopwords
crude<-tm_map(crude, removeNumbers)
crude<-tm_map(crude, function(x) removeWords(x,stopwords())</pre>
stopwords()
# from frequency counts
tdm<-TermDocumentMatrix(crude)
m<-as.matrix(tdm)
v<-sort(rowSums(m), decreasing=TRUE)</pre>
d<-data.frame(word=names(v), freq=v)</pre>
# plot a word cloud
# to see detail help(wordcloud)
par(mfrow=c(1, 1))
wordcloud(d$word, d$freq, random.order=FALSE)
```

텍스트마이닝 결과: oil, said, price

```
spokeswoman

officials mizrahi
named export estimates
named export export export in in in interpretation in increase
weeks dollars
however brings contract of export export of export export of export ex
```

Ref: https://www.r-bloggers.com/text-mining/



4. 텍스트마이닝 예제

help(wordcloud)

Plot a word cloud Usage wordcloud(words, freq, scale=c(4,.5), min.freq=3, max.words=Inf, random.order=TRUE, random.color=FALSE, rot.per=.1, colors="black", ordered.colors=FALSE, use.r.layout=FALSE, fixed.asp=TRUE, ...) **Arguments** words the words freq their frequencies scale A vector of length 2 indicating the range of the size of the words. words with frequency below min.freq will not be plotted min.freq max.words Maximum number of words to be plotted, least frequent terms dropped random.order plot words in random order. If false, they will be plotted in decreasing frequency random.color choose colors randomly from the colors. If false, the color is chosen based on the frequency rot.per proportion words with 90 degree rotation color words from least to most frequent colors ordered.colors if true, then colors are assigned to words in order



7

5. 텍스트마이닝 : 코퍼스(corpus)

8-3. 텍스트마이닝 I

• 코퍼스(corpus, 말뭉치): 텍스트집합을 의미

(예) 신문기사(html, text), SNS (tweeter, facebook)

• 코퍼스 기반 언어연구*, 빅데이터 시대의 언어분석+

• Source의 종류

DirSource(): 디렉토리

DataframeSource(): R 데이터프레임

VectorSource() : R 벡터 XMLSource() : XML 파일

URISource(): URI

• 문서포맷과 Reader


readPlain: Plain Text

readPDF: pdf 파일

readDOC: MS word 문서

readXML: XML문서





+빅데이터 시대의 언어연구, 이민행, 2015

Wk8-4: 텍스트마이닝 II



-

6. 텍스트마이닝 : 함수

8-4. 텍스트마이닝 II

•텍스트마이닝에서 사용되는 함수


함수	설명과 예제코드							
str(x[[1]])	데이터의 구조에 대한 정보 (첫번째 파일의 구조)							
	str(crude[[1]])							
content(x[[1]])	문서의 내용 (첫번째 문서의 내용)							
meta(x)	메타정보 (x에 기록되어있는 저자, 날자, id, 등 정보를 보여줌) meta(crude[[1]])							
inspect(x)	코퍼스, 텍스트, 문서행렬 등에 대한 정보를 제공							
	data(crude)							
	inspect(crude[1:3])							
	inspect(crude[[1]])							
	tdm <- TermDocumentMatrix(crude)							
	inspect(tdm)							
lapply(x, content) 파일의 내용을 보여줌								
	lapply(crude, content)							



2

6. 텍스트마이닝: 함수


crude[[1]] 데이터 : 첫번째 기사 (아래와 같은 XML파일 형태로 저장)




6. 텍스트마이닝 함수

8-4. 텍스트마이닝 II

• inspect 함수



각 파일에 char숫자



7. 텍스트마이닝 전처리 함수

•텍스트 전처리

함수	설명			
tm_map(x, removePunctuation) (예) crude<-tm_map(crude, removePunctuation)	문장부호 제거 (. , "" ' ')			
tm_map (x, stripWhitespace) (예) crude<-tm_map(crude,stripWhitespace)	공백문자 제거			
tm_map (x, removeNumbers) (예) crude<-tm_map(crude, removeNumbers)	숫자 제거			



5

7. 텍스트마이닝 전처리 함수

8-4. 텍스트마이닝 II

• 텍스트 전처리: 문장부호 없애기- tm_map(x, removePunctuation)

```
str(crude[[1]])
content(crude[[1]])
```

```
> content(crude[[1]])
```

[1] "Diamond Shamrock Corp said that\neffective today it had cut its con tract prices for crude oil by\n.50 dlrs a barre...n The reduction br ings its posted price for West Texas\nIntermediate to 16.00 dlrs a barre 1, the copany said.\n \"The price reduction today was made in the lig ht of falling\noil product prices and a weak crude oil market,\" a company\nspokeswoman said.\n Diamond is the latest in a line of U.S. oil c ompanies that\nhave cut its contract, or posted, prices over the last two days\nciting weak oil markets.\n Reuter"

```
# 1. remove punctuation in documnet
crude<-tm_map(crude, removePunctuation)
content(crude[[1]])</pre>
```

문장부호 제거 (., "" ' ')

> content(crude[[1]])

[1] "Diamond Shamrock Corp said that\neffective today it had cut its con tract prices for crude oil by\n150 dlrs a barrel\n The reduction brin



7. 텍스트마이닝 전처리 함수

• 텍스트 전처리 : 숫자 제거- tm_map(x, removeNumbers)

```
# 2. remove numbers
crude<-tm_map(crude, removeNumbers)
content(crude[[1]])</pre>
```

숫자 제거



[1] "Diamond Shamrock Corp said that\neffective today it had cut its con tract prices for crude oil by\n dlrs a barrel\n The reduction brings

• 텍스트 전처리 : stopwords 제거 - 언어별로 다름, 지정할수 있음

```
# 3. remove stopwords
crude<-tm_map(crude, function(x) removeWords(x,stopwords()))
content(crude[[1]])</pre>
```

that, it, had, its, for, by, The 제거

> content(crude[[1]])

[1] "Diamond Shamrock Corp said \neffective today cut contract prices crude oil \n dlrs barrel\n The reduction brings posted price Wes



7

7. 텍스트마이닝 전처리 함수

8-4. 텍스트마이닝 II

• 텍스트전처리 : stopword 리스트

```
# 3. remove stopwords
crude<-tm_map(crude,
content(crude[[1]])
stopwords()</pre>
```


```
> stopwords()
 [1] "i"
                    "me"
                                                "myself"
                                                              "we"
 [6] "our"
                    "ours"
                                  "ourselves"
                                                "you"
                                                              "your"
[11] "yours"
                    "vourself"
                                  "yourselves" "he"
                                                              "him"
[16] "his"
                    "himself"
                                  "she"
                                                "her"
                                                              "hers"
                                                "itself"
[21] "herself"
                    "it"
                                  "its"
                                                              "they"
[26] "them"
                    "their"
                                  "theirs"
                                                "themselves" "what"
[31] "which"
                                  "whom"
                                                "this"
                    "who"
                                                              "that"
                                  "am"
                                                "is"
[36] "these"
                    "those"
                                                              "are"
[41] "was"
                    "were"
                                  "be"
                                                "been"
                                                              "being"
[46] "have"
                    "has"
                                  "had"
                                                "having"
                                                              "do"
[51] "does"
                    "did"
                                  "doing"
                                                "would"
                                                              "should"
                                                              "he's"
[56] "could"
                    "ought"
                                  "i'm"
                                                "you're"
```

stopwords("en") 1747|| stopwords("SMART") 5177||



8. 텍스트마이닝 수행

• 문서행렬을 구성: TermDocumentMatrix(문서이름)






9

8. 텍스트마이닝 수행

8-4. 텍스트마이닝 II

• 문서행렬을 행렬로 변환



• 단어의 빈도 순서로 정렬

6. sorting in high frequency to low v<-sort(rowSums(m), decreasing=TRUE) v[1:10]


각 단어에 대한 빈도의 합(행기준) 가장높은것부터 [1:10]번까지

> v[1:10]											
oil	said p	rices	opec	mln	the	last	bpd	dlrs	crude		
85	73	48	42	31	26	24	23	23	21		



8. 텍스트마이닝 수행

- 단어 이름과 빈도를 결합한 행렬을 데이터 프레임으로 저장
- crude관련기사 파일로부터 962개의 단어들을 분류하여 빈도를 계산



11

9. 텍스트마이닝 결과 그리기


8-4. 텍스트마이닝 II

• 빈도가 가장 높은 단어부터 그리기

7-1. Now lets try it with frequent words plotted first wordcloud(d\$word,d\$freq,c(8,.5),2,,FALSE,.1) free february emirates economy fell contract exports year foreign must expected traders come bbl first corpeconomic daily reserves bank qatar arabia expected traders week production says west opecs analysts sheikh new government company plans accord agreement gulf crude bpdbarrel december imports graph one price plans accord agreement gulf crude bpdbarrel december imports graph one price plans graph one plans graph graph one plans graph graph one plans graph graph one plans graph minister six reserve actor nymex odirs day Treport 가장 빈도가 높은 단어 6개 he∄töday > head(d) In month word freq ability sources sources also for they apply also for they also for the sources are they also for the sources are they also for t last futures oil oil 85 said said 73 Will^{hit} billion prices prices 48 barrels present ceiling group ceiling market on the process of the 42 opec opec mlnmlnthe the

9. 텍스트마이닝 결과 그리기

• 빈도가 가장 높은 단어부터 그리기 (색상 넣기)



9. 텍스트마이닝: 한글

8-4. 텍스트마이닝 II

13

• 한글문서에서 텍스트마이닝

```
# 9. Korean text #####
# takes quite long for installing
install.packages("KoNLP")
library(KoNLP)
# Korean dictionary
useSejongDic (backup=T)
```

- 설치에 시간이 약간 걸림
- 단계별로 filtering하는 방법은 동일
- 한글문서로 텍스트마이닝






8-4. 텍스트마이닝 II

10. 텍스트마이닝 데이터 저장소 : 참고

• tm패키지의 예제데이터와 저장소



10. 텍스트마이닝 데이터 저장소 : 참고

8-4. 텍스트마이닝 II

• crude 데이터

Crude 데이터 (tm패키지에 들어있는 예제데이터)

